


24 2. Statistical Learning



En este diagrama podemos ver que según el método que usemos hay algunos que son mas interpretables mientras que otros son mas flexibles.

División por supervisión

Podemos dividir el machine learning en dos:

- **Supervisado:** Nosotros le entregamos "alimentación" a la máquina para de esta manera explicarle que es lo que estamos buscando
- **No supervisado:** El sistema trata de aprender sin un "profesor"
- **Semi-supervisado:** Nosotros alimentamos a algoritmo, pero este decide ciertas cosas, como google photos cuando agrupa por persona
- **Auto-supervisado:** En este el algoritmo trata de elegir la mejor opcion en base a una gran cantidad de data



Figure 1-12. Self-supervised learning example: input (left) and target (right)

- **Aprendizaje reforzado:** En este el sistema recibe una recompensa o un castigo dependiendo del resultado que tiene

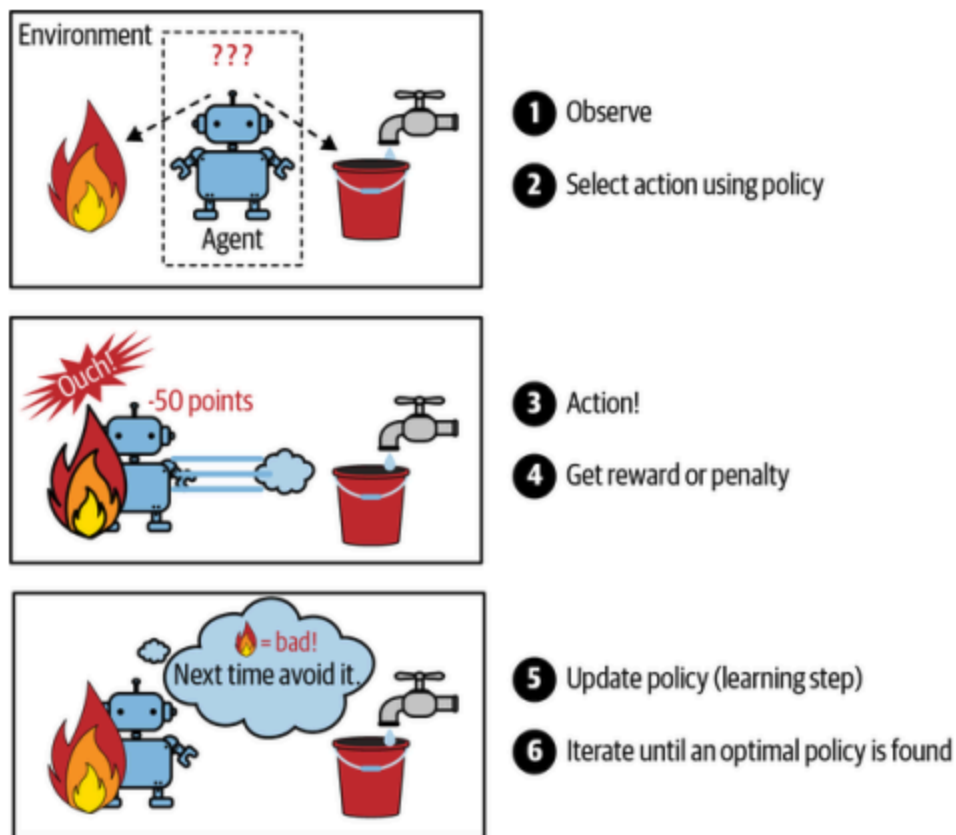


Figure 1-13. Reinforcement learning

Procesamiento y visualización de datos(Materia)

- variable: característica que se mide u observa en un conjunto de datos
- Observación: conjunto de valores que se registran para una variable en particular
- Distribución: característica o atributo que se mide
- Correlación: relación entre datos

Tipo de datos

Datos estructurados

ID Paciente	Nombre	Apellido	Fecha de Nacimiento	Sexo	Dirección	Teléfono
1	Juan	Pérez	01/01/1990	H	Av. Libertad 123	555-1234
2	María	García	02/02/1992	M	Calle 45 #23	555-5678
3	Pedro	Rodríguez	03/03/1995	H	Av. Independencia 456	555-9012
4	Ana	Sánchez	04/04/1991	M	Calle 12 #56	555-1111

Datos no estructurados

Nombre: Juan Pérez
Edad: 35
Sexo: Masculino
Diagnóstico: Diabetes tipo 2
Medicamentos: - Metformina - Insulina
Alergias: - Penicilina

Archivos JSON y XML.

Datos semi-estructurados

Fuente de datos

registro, sensores, bases de datos, investigaciones, métodos de consulta, etc. Todos esos son métodos para obtener datos.



Procesamiento de datos

Problema de datos:

- Valores faltantes o duplicados
- Valores inconsistentes
- Ruido
- Errores de formato

Técnica y herramientas:

- Eliminación y/o remplazo de datos faltantes
- Corrección de formato
- Eliminación de duplicados

Normalización

Escalado máximo-mínimo (Min-Max)

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Z-score (Estandarización)

$$x' = \frac{x - \mu}{\sigma}$$

Normalización máxima (Max Norm)

$$x' = \frac{x}{x_{\max}}$$

Transformación de variables

Codificación One-Hot

Ejemplo: Rojo $\rightarrow (1,0,0)$, Azul $\rightarrow (0,1,0)$

Codificación ordinal

Ejemplo: Bajo (1), Medio (2), Alto (3)

Discretización de variables numéricas

Ejemplo: $[0, 10] \rightarrow$ "bajo", $[11, 20] \rightarrow$ "medio"

Medida de tendencia central y dispersión

Media (promedio)

Media aritmética:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

Promedio de los valores de un conjunto de datos.


Desviación estándar

Fórmula:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

Mide la dispersión de los datos respecto a la media.

Restar la media o estandarizar: Al restar μ_x a los datos se centra el espacio en las medias, por lo que la media de los datos estandarizados es cero ($\mu_x = E[x] = 0$)



- **Varianza:** medida que indica qué tan dispersos están los valores con respecto a la media.


$$\text{var}(x) = \sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$$

- **Covarianza:** representa la tasa de cambio entre dos variables aleatorias.

$$\text{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)(y_i - \mu_y)$$

- **Correlación:** mide la relación lineal entre dos variables, estandarizando la covarianza.

$$\text{Corr}(x, y) = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$



Sea el vector $\mathbf{x} = \{x_1, \dots, x_N\}$, un vector de variables aleatorias.

$$\mathbf{C}_x = \mathbf{C}_x^{N \times N} = (c_{ij} | c_{ij} = \text{Cov}(x_i, x_j))$$

Teniendo en cuenta que $\text{Cov}(x, x) = \sigma_x^2$ y sea $\mathbf{x} = \{x, y, z\}$:


$$\mathbf{C}_x = \begin{pmatrix} \sigma_x^2 & \text{Cov}(x, y) & \text{Cov}(x, z) \\ \text{Cov}(x, y) & \sigma_y^2 & \text{Cov}(y, z) \\ \text{Cov}(x, z) & \text{Cov}(y, z) & \sigma_z^2 \end{pmatrix}$$

- $\mathbf{C}_x$ es una matriz simétrica.
- La matriz de covarianza también se puede definir como:

$$\mathbf{C}_x = E[(\mathbf{x} - \mu_x)(\mathbf{x} - \mu_x)^T] = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k \mathbf{x}_k^T - \mu_x \mu_x^T)$$

► **Escala:**

- La covarianza depende de las unidades de las variables.
- La correlación es adimensional, normalizada entre -1 y 1.




► **Comparabilidad:**


- La covarianza no es directamente comparable entre distintos pares de variables.
- La correlación permite comparaciones directas entre diferentes pares de variables.

Detección de Outliers (Valores Atípicos)

Son datos que se desvían significativamente del patrón general de un conjunto de datos. Pueden ser causados por errores de medición, variabilidad natural o eventos excepcionales.



- **Método de la Distancia:** Identifica outliers basados en la distancia a la media o a otros puntos de datos (e.g., Z-score).
- **Método de la Densidad:** Detecta outliers como puntos con baja densidad de vecinos (e.g., DBSCAN).
- **Otros Métodos:** Incluyen métodos basados en modelos estadísticos, métodos de aprendizaje automático (e.g., Isolation Forest), etc.




- ▶ **Mediana (Línea Amarilla):** Valor central, divide los datos en 50/50.
- ▶ **Caja (IQR):** Rango intercuartílico (Q1 a Q3), 50 % central de los datos.
 - Q1: 25 % de los datos por debajo.
 - Q3: 75 % de los datos por debajo.
- ▶ **Líneas "Mínimo" "Máximo":** Límites de datos no atípicos ($Q1 - 1.5 * IQR$, $Q3 + 1.5 * IQR$).
- ▶ **Outliers (Puntos Fuera de los Bigotes):** Valores atípicos, significativamente diferentes del resto.

Distribución Gaussiana (Normal)

Definición: Una variable aleatoria X sigue una distribución normal si su función de densidad de probabilidad es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- ▶ μ : media
- ▶ σ^2 : varianza
- ▶ Forma de campana, simétrica¹².




¹Algunos fenómenos naturales siguen esta distribución. Se utiliza para modelar variables continuas como la altura, el peso, la inteligencia, entre otras.

²La distribución normal es simétrica y tiene una curva en forma de campana, con la mayoría de los datos agrupados cerca de la media.

Definición: Una variable aleatoria X sigue una distribución uniforme en el intervalo $[a, b]$ si su función de densidad de probabilidad es:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{en otro caso} \end{cases}$$


- Todos los valores tienen la misma probabilidad.
- Distribución rectangular.



Definición: Una variable aleatoria X sigue una distribución binomial si cuenta el número de éxitos en n ensayos de Bernoulli³, con probabilidad de éxito p :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k},$$

- Modela procesos de éxito/fracaso.
- Se aproxima a la normal para n grande.



³Experimentos aleatorios que tienen solo dos posibles resultados: éxito o fracaso. Ejemplo: lanzar una moneda.

Histograma de imagen blanco y negro

Imaginemos un histograma de una imagen en blanco y negro donde :

$$h(t) = n_k$$

donde k es $= \{0, \dots, L\}$ donde L es el nivel de grises y n_k el numero de píxeles con valores de grises, también podemos normalizarlo por el valor de grises como

$$p(k) = \frac{n_k}{n}$$

n = numero total de pixeles en la imagen

Distribución gaussiana (normal)

Una variable X que sigue la distribución normal:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Feature selection for lineal regression

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p +$$


All Features




Feature Selection





Final Features



hay veces en las que necesitamos filtrar datos en bases a características





En ridge buscamos reducir los betas, mientras que en lasso eliminamos características

z-score

El **Z-score (o t-score)** en regresión mide cuántas desviaciones estándar está un coeficiente $\hat{\beta}_i$ del valor cero. Es una herramienta clave para:

- Evaluar si una variable tiene un efecto significativo sobre y .
- Realizar pruebas de hipótesis sobre $H_0 : \beta_i = 0$.

Un valor alto (en valor absoluto) sugiere que la variable es relevante. Si es bajo, podría ser ruido.

Evalúa el z-score que tanto efecto tiene sobre y , si el valor es alto significa que es relevante si es bajo no es importante

1. Ajustar el modelo:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p +$$

2. Obtener las predicciones:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p$$

3. Calcular la varianza residual:

$$\hat{\sigma}^2 = \frac{1}{N - p - 1} \sum (y - \hat{y})^2$$

Cuando ajustamos el modelo, obtenemos el valor de predicción, y cuando calculamos esta predicción podemos calcular la varianza residual que nos dice cuánta varianza hay entre nuestro modelo con la predicción

4. Obtener la matriz de varianzas¹ :

$$\text{Var}(\hat{\beta}) = \hat{\sigma}^2 (X^T X)^{-1}$$

5. Calcular el error estándar:

$$SE(\hat{\beta}_i) = \sqrt{\text{Var}(\hat{\beta}_i)}$$

6. Calcular el t-score (Z-score):

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

cada beta nos dara un valor t

- | | |
|--|---|
| 1. age: Edad en años. | 7. s3: Lipoproteínas de alta densidad (HDL). |
| 2. sex: Sexo (masculino o femenino). | 8. s4: Relación colesterol total/HDL. |
| 3. bmi: Índice de masa corporal (BMI). | 9. s5: Logaritmo del nivel de triglicéridos en suero (LTG). |
| 4. bp: Presión arterial media. | 10. s6: Nivel de glucosa en sangre (GLU). |
| 5. s1: Colesterol sérico total (TC). | |
| 6. s2: Lipoproteínas de baja densidad (LDL). | |

	coef	std err	t
const	152.1335	2.576	59.061
x1	-10.0099	59.749	-0.168
x2	-239.8156	61.222	-3.917
x3	519.8459	66.533	7.813
x4	324.3846	65.422	4.958
x5	-792.1756	416.680	-1.901
x6	476.7390	339.030	1.406
x7	101.0433	212.531	0.475
x8	177.0632	161.476	1.097
x9	751.2737	171.900	4.370
x10	67.6267	65.984	1.025

los valores cercanos a 0 se deberían ignorar, los positivos y negativos grandes son importantes

- ▶ El Z-score (o más correctamente, t-score) indica cuántas desviaciones estándar está el coeficiente de $\hat{\beta}_i$ respecto a cero.
- ▶ Nos ayuda a decidir si una variable es significativa en el modelo.

Interpretación

- ▶ **t-score alto** ($|t| > 2$): variable probablemente significativa.
- ▶ **t-score bajo** ($|t| \approx 0$): variable no significativa → candidata a eliminar.

Incluir muchas variables irrelevantes puede hacer que el modelo:

- ▶ Sea más complejo de interpretar.
- ▶ Tenga menor capacidad de generalizar (sobreajuste).
- ▶ Tarde más en entrenarse y validarse.

Objetivo

Seleccionar el subconjunto más informativo de variables, descartando las redundantes o inútiles.

Dado un conjunto de datos con muchas variables de entrada, no es recomendable incluir todas las variables de entrada en la ecuación de regresión lineal. En su lugar, es recomendable seleccionar un subconjunto de esas características que pueda predecir la salida con precisión.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p +$$

- ▶ *Stepwise regression* es una técnica de selección de características en la regresión lineal múltiple (MLR).
- ▶ Existen tres tipos de *stepwise regression*: **backward elimination, forward selection, and bidirectional elimination.**

Su propósito principal es identificar y utilizar el subconjunto más relevante de características del dataset, descartando aquellas que son irrelevantes o redundantes - Evitar sobreajuste.

1. Técnicas secuenciales simples:

- ▶ **Forward Selection:** empieza con ninguna variable y las agrega una a una.
- ▶ **Backward Selection:** empieza con todas las variables y elimina las menos útiles.

2. Técnicas avanzadas:

- ▶ **Stepwise Selection:** agrega y elimina variables según su efecto en el modelo.
- ▶ **Recursive Feature Elimination (RFE):** elimina de forma iterativa la variable menos relevante según el modelo.

Backward selection

Backward Selection es una técnica de selección de variables en regresión lineal. Comienza con todas las variables del conjunto de datos e itera eliminando una a una las que aportan menos al modelo, típicamente según su p-valor.

Pasos del algoritmo:

1. Ajustar un modelo con **todas las variables disponibles**.
2. Evaluar la **significancia estadística** de cada variable (usualmente con p-valor o t-score).
3. Eliminar la variable **menos significativa**.
4. Reajustar el modelo y repetir el proceso hasta que todas las variables restantes sean significativas.

Ventajas / Limitaciones:

- ▶ Reduce el riesgo de **sobreajuste** al eliminar variables irrelevantes.
- ▶ Es simple de implementar y comprender.
- ▶ **Puede eliminar variables importantes si hay multicolinealidad.**
- ▶ No garantiza encontrar el **mejor subconjunto global** de variables.

p-value

1. Calcular el t-value:

$$t = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

2. Consultar la distribución t de Student con $n - p - 1$ grados de libertad:

$$\text{p-value} = 2 \cdot P(T > |t|), \quad T \sim t(df)$$

donde n y p son el número de observaciones y el número de variables independientes, respectivamente.


3. Interpretación:

- ▶ p-valor pequeño (< 0.05): evidencia contra la hipótesis nula $H_0 : \beta_i = 0$.
- ▶ p-valor grande: no hay evidencia suficiente para rechazar H_0 .

Ejemplo:

$$\begin{aligned} \hat{\beta} &= 0,5, & SE &= 0,2, & t &= \frac{0,5}{0,2} = 2,5 \\ df &= 50, & p &= 2 \cdot P(T > 2,5) \approx 0,016 \end{aligned}$$

Distribución t-Student



- Distribución de probabilidad que surge del problema de estimar la media de una población normalmente distribuida cuando el tamaño de la muestra es pequeño y la desviación estándar poblacional es desconocida ($k = df$).

Ejemplo: calcular p-value en python

```
1 from scipy import stats
2
3 # t-score observado y grados de libertad
4 t = 2.5
5 df = 50 # n mero de datos - n mero de par metros (betas), mientras m s variables,
6 menos grados de libertad
7
8 # p-valor bilateral
9 p_value = 2 * (1 - stats.t.cdf(abs(t), df))
10 print(f"p-value: {p_value:.4f}") # Resultado: 0.0160
```

en la distribución t-student es como una gaussiana pero desconocemos la desviación estandar

Consultar la distribución t

Se busca conocer cuán probable sería obtener un estadístico t tan extremo como el observado si la hipótesis nula fuera cierta (es decir, si $\beta_i = 0$).

Para eso, comparamos nuestro valor de t con la distribución t de Student, que depende de los grados de libertad del modelo:

$$df = n - p - 1$$

El área bajo la curva desde $|t|$ hacia los extremos nos da el **p-value**. Si ese área es pequeña, el valor observado es poco probable bajo H_0 , y lo rechazamos.

t-value (o Z-score)

Es el estadístico de prueba que mide cuántas desviaciones estándar se aleja el coeficiente $\hat{\beta}_i$ del valor nulo (cero). Se calcula así:

$$t = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

Valores grandes (en valor absoluto) indican mayor evidencia contra la hipótesis nula.

p-value

Es la **probabilidad** de obtener un t-value tan extremo como el observado (o más), **asumiendo que la hipótesis nula es cierta**. Se interpreta así:

- ▶ **p pequeño** (por ejemplo, < 0.05): hay evidencia suficiente para rechazar H_0 .
- ▶ **p grande**: el coeficiente puede no ser significativamente distinto de cero.

Relación: El t-value se calcula a partir del modelo, y el p-value se obtiene consultando una distribución t de Student con $N - p - 1$ grados de libertad.

Forward step-wise selection

Es una combinación del backward y el forward

Agrega variables de forma secuencial al modelo, comenzando con ninguna.

► **Paso 0: Modelo Vacío**

- Iniciar con un modelo sin predictores (solo el intercepto).
- Evaluar el rendimiento inicial (ej., $R^2 \approx 0$).

► **Paso 1: Añadir la Primera Característica**

- Evaluar modelos simples con cada característica individualmente.
- Seleccionar la característica que maximiza la mejora del rendimiento.
- Añadir permanentemente esta característica al modelo.

► **Paso 2: Añadir la Siguiente Característica**

- Mantener las características seleccionadas previamente.
- Evaluar modelos añadiendo cada una de las características restantes.
- Seleccionar la característica restante que maximiza la mejora del rendimiento.
- Añadir permanentemente esta característica al modelo.

Pasos Siguientes (iterar)

- Repetir el Paso 2.
- En cada paso, evaluar la adición de cada característica no seleccionada al conjunto actual.
- Añadir la característica que produce la mayor mejora en el rendimiento.

Criterios de Parada

- No hay mejora significativa en el rendimiento.
- Se alcanza un número predefinido de características.
- Criterios basados en pruebas estadísticas (ej., valor p del coeficiente).

Ventajas:

- Computacionalmente más eficiente que probar todas las combinaciones.
- Permite identificar subconjuntos relevantes de variables.

OLS Regression Results

```

=====
Dep. Variable:          y      R-squared:          0.609
Model:                  OLS    Adj. R-squared:       0.609
Method:                 Least Squares    F-statistic:      2815.
Date:                   Wed, 16 Apr 2025    Prob (F-statistic): 0.00
Time:                   07:56:16    Log-Likelihood:    -15823.
No. Observations:      14448    AIC:               3.166e+04
Df Residuals:          14439    BIC:               3.173e+04
Df Model:               8
Covariance Type:        nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	2.0689	0.006	343.624	0.000	2.057	2.081
MedInc	0.8470	0.009	89.283	0.000	0.828	0.866
HouseAge	0.1218	0.007	18.240	0.000	0.109	0.135
AveRooms	-0.3021	0.017	-17.362	0.000	-0.336	-0.268
AveBedrms	0.3690	0.017	21.978	0.000	0.336	0.402
Population	-0.0009	0.006	-0.138	0.890	-0.013	0.012
AveOccup	-0.0350	0.005	-6.889	0.000	-0.045	-0.025
Latitude	-0.8940	0.018	-49.265	0.000	-0.930	-0.858
Longitude	-0.8689	0.018	-48.757	0.000	-0.904	-0.834

```

=====
Omnibus:                2973.049    Durbin-Watson:      1.964
...
Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```

¿Qué representa el t-value?

Es el estadístico de prueba que indica cuántas desviaciones estándar está el coeficiente estimado $\hat{\beta}_i$ del valor nulo (0):

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

- Valores grandes (en valor absoluto) → mayor evidencia de que $\hat{\beta}_i \neq 0$.

¿Qué representa P>|t|?

Es el **p-valor** asociado al t-score. Indica la probabilidad de observar ese valor (o uno más extremo) si la hipótesis nula es cierta:

$$H_0 : \beta_i = 0$$

- Si $p < 0,05$: evidencia estadística suficiente para rechazar H_0 la variable es significativa.
- Si $p > 0,05$: no hay evidencia suficiente variable posiblemente irrelevante.

Los modelos de regresión lineal requieren variables numéricas. Las variables categóricas (como colores, géneros, regiones) deben ser transformadas para que el modelo las entienda. Las dummy variables permiten incorporar estas categorías de forma cuantitativa sin imponer un orden falso².

- ▶ Variables categóricas convertidas en valores 0 o 1. Codificación one-hot.
- ▶ Permiten que los modelos de regresión lineal trabajen con variables cualitativas.

Ejemplo:

Color	Dummy_Rojo	Dummy_Verde	Dummy_Azul
Rojo	1	0	0
Verde	0	1	0
Azul	0	0	1

Modelo de Regresión:

$$y = \beta_0 + \beta_1(\text{Dummy_Rojo}) + \beta_2(\text{Dummy_Verde}) +$$

- ▶ Una Permite que las variables categóricas influyan en el modelo de manera cuantitativa.
- ▶ Los coeficientes representan la diferencia respecto a la categoría de referencia.

²Si la transformarás directamente a números (por ejemplo, rojo = 1, azul = 2, verde = 3), el modelo asumiría que hay un orden entre esos valores (como si verde fuera "mayor" que azul, y azul mayor que rojo).

Q-Q plot

- ▶ QQ plot significa *"gráfico cuantil-cuantil"*.
- ▶ Se utiliza para comparar la distribución de los residuos con una distribución normal teórica.
- ▶ Es útil para verificar si los errores del modelo de regresión cumplen con el supuesto de normalidad.
- ▶ En regresión lineal, se asume que los residuos tienen distribución normal.
- ▶ Si los residuos no son normales, los intervalos de confianza y las pruebas pueden no ser válidos.
- ▶ El QQ plot ayuda a diagnosticar visualmente esta suposición.

Modelo lineal clásico:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \text{con } \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

¿Qué implica esto?

- ▶ Los residuos del modelo (errores) deberían seguir una distribución normal.
- ▶ Este supuesto no afecta la estimación de $\hat{\beta}$, pero sí:
 - La validez de los intervalos de confianza.
 - La interpretación de los p-valores.
 - Las predicciones con incertidumbre.


¿Qué pasa si no se cumple?

- ▶ Los estimadores siguen siendo insesgados, pero la inferencia puede ser errónea.
- ▶ Podemos usar transformaciones (log, raíz) o modelos no paramétricos.

¿Para qué sirve?

Compara la distribución de los residuos con una distribución normal teórica. Es una herramienta visual para diagnosticar si los residuos siguen una distribución normal.

- ▶ **Puntos alineados en la diagonal:** distribución aproximadamente normal.
- ▶ **Curvas en S o desviaciones grandes:** indicios de asimetría o colas pesadas.



La normalidad de residuos es esencial para:

- ▶ Calcular intervalos de confianza para $\hat{y}$ (valor esperado).
- ▶ Estimar intervalos de predicción para nuevas observaciones.
- ▶ Obtener p-valores confiables.


Diagnóstico

Q-Q Plot = Inspección visual del supuesto de normalidad. Si el patrón se desvía mucho de la diagonal, se recomienda:


- ▶ Transformar la variable dependiente (log, raíz).
- ▶ Usar modelos robustos o métodos no paramétricos.

-
- ▶ **Intervalos de confianza:** Los intervalos de confianza son rangos que nos dan una idea de cuán seguros estamos sobre los valores estimados por el modelo de regresión. Se usan principalmente en dos contextos:
 - Intervalo de confianza para el valor esperado $\hat{y}$ ó Intervalo de confianza para la predicción de una nueva observación.
 - Ayudan a cuantificar la incertidumbre del modelo.
 - Son fundamentales para hacer inferencias confiables.
 - ▶ Residuos con distribución normal (supuesto).

Normal Q-Q Plot



QQ Plot de los residuos



- Si los puntos siguen una línea recta diagonal, los residuos son aproximadamente normales.
- Desviaciones sistemáticas alertan posibles problemas:
 - Curvatura en los extremos.
 - Forma de S en el centro se asocia a distribución sesgada.

No se encontró "todoDel1-7_page-0001.jpg".

No se encontró "todoDel1-7_page-0002.jpg".

No se encontró "todoDel1-7_page-0003.jpg".

No se encontró "todoDel1-7_page-0004.jpg".

No se encontró "todoDel1-7_page-0005.jpg".

No se encontró "todoDel1-7_page-0006.jpg".

No se encontró "todoDel1-7_page-0007.jpg".

No se encontró "todoDel1-7_page-0008.jpg".

No se encontró "todoDel1-7_page-0009.jpg".

No se encontró "todoDel1-7_page-0010.jpg".

No se encontró "todoDel1-7_page-0011.jpg".

No se encontró "todoDel1-7_page-0012.jpg".

No se encontró "todoDel1-7_page-0013.jpg".

No se encontró "todoDel1-7_page-0014.jpg".

No se encontró "todoDel1-7_page-0015.jpg".

No se encontró "todoDel1-7_page-0016.jpg".

No se encontró "todoDel1-7_page-0017.jpg".

No se encontró "todoDel1-7_page-0018.jpg".

No se encontró "todoDel1-7_page-0019.jpg".

No se encontró "todoDel1-7_page-0020.jpg".

No se encontró "todoDel1-7_page-0021.jpg".

No se encontró "todoDel1-7_page-0022.jpg".

No se encontró "todoDel1-7_page-0023.jpg".

No se encontró "todoDel1-7_page-0024.jpg".

No se encontró "todoDel1-7_page-0025.jpg".

No se encontró "todoDel1-7_page-0026.jpg".

No se encontró "todoDel1-7_page-0027.jpg".

No se encontró "todoDel1-7_page-0028.jpg".

No se encontró "todoDel1-7_page-0029.jpg".

No se encontró "todoDel1-7_page-0030.jpg".

No se encontró "todoDel1-7_page-0031.jpg".

No se encontró "todoDel1-7_page-0032.jpg".

No se encontró "todoDel1-7_page-0033.jpg".

No se encontró "todoDel1-7_page-0034.jpg".

No se encontró "todoDel1-7_page-0035.jpg".

No se encontró "todoDel1-7_page-0036.jpg".

No se encontró "todoDel1-7_page-0037.jpg".

No se encontró "todoDel1-7_page-0038.jpg".

No se encontró "todoDel1-7_page-0039.jpg".

No se encontró "todoDel1-7_page-0040.jpg".

No se encontró "todoDel1-7_page-0041.jpg".

No se encontró "todoDel1-7_page-0042.jpg".

No se encontró "todoDel1-7_page-0043.jpg".

No se encontró "todoDel1-7_page-0044.jpg".

No se encontró "todoDel1-7_page-0045.jpg".

No se encontró "todoDel1-7_page-0046.jpg".

No se encontró "todoDel1-7_page-0047.jpg".

No se encontró "todoDel1-7_page-0048.jpg".

No se encontró "todoDel1-7_page-0049.jpg".

No se encontró "todoDel1-7_page-0050.jpg".

No se encontró "todoDel1-7_page-0051.jpg".

No se encontró "todoDel1-7_page-0052.jpg".

No se encontró "todoDel1-7_page-0053.jpg".

No se encontró "todoDel1-7_page-0054.jpg".

No se encontró "todoDel1-7_page-0055.jpg".

No se encontró "todoDel1-7_page-0056.jpg".

No se encontró "todoDel1-7_page-0057.jpg".

No se encontró "todoDel1-7_page-0058.jpg".

No se encontró "todoDel1-7_page-0059.jpg".

No se encontró "todoDel1-7_page-0060.jpg".

No se encontró "todoDel1-7_page-0061.jpg".

No se encontró "todoDel1-7_page-0062.jpg".

No se encontró "todoDel1-7_page-0063.jpg".

No se encontró "todoDel1-7_page-0064.jpg".

No se encontró "todoDel1-7_page-0065.jpg".

No se encontró "todoDel1-7_page-0066.jpg".

No se encontró "todoDel1-7_page-0067.jpg".

No se encontró "todoDel1-7_page-0068.jpg".

No se encontró "todoDel1-7_page-0069.jpg".

No se encontró "todoDel1-7_page-0070.jpg".

No se encontró "todoDel1-7_page-0071.jpg".

No se encontró "todoDel1-7_page-0072.jpg".

No se encontró "todoDel1-7_page-0073.jpg".

No se encontró "todoDel1-7_page-0074.jpg".

No se encontró "todoDel1-7_page-0075.jpg".

No se encontró "todoDel1-7_page-0076.jpg".

No se encontró "todoDel1-7_page-0077.jpg".

No se encontró "todoDel1-7_page-0078.jpg".

No se encontró "todoDel1-7_page-0079.jpg".

No se encontró "todoDel1-7_page-0080.jpg".

No se encontró "todoDel1-7_page-0081.jpg".

No se encontró "todoDel1-7_page-0082.jpg".

No se encontró "todoDel1-7_page-0083.jpg".

No se encontró "todoDel1-7_page-0084.jpg".

No se encontró "todoDel1-7_page-0085.jpg".

Defining the projet scope: se establecen las metas y como se planea lograrlo

No se encontró "todoDel1-7_page-0086.jpg".

No se encontró "todoDel1-7_page-0087.jpg".

Data understanding: es la fase donde se aplica la ciencia y se trata de entender los datos, sus orígenes , problemas, etc.

No se encontró "todoDel1-7_page-0088.jpg".

No se encontró "todoDel1-7_page-0089.jpg".

Data collection: corresponde a los medios y de donde recolectaremos los datos.

No se encontró "todoDel1-7_page-0090.jpg".

Data preparation: requiere a aplicar tecnicas para manejar outliers, Nan y normalizacion

No se encontró "todoDel1-7_page-0091.jpg".

No se encontró "todoDel1-7_page-0092.jpg".

No se encontró "todoDel1-7_page-0093.jpg".

No se encontró "todoDel1-7_page-0094.jpg".

Analysis and modeling: encontramos patrones de datos, y contruimos un modelo capaz de predecir los datos

No se encontró "todoDel1-7_page-0095.jpg".

Validation: aplicamos distintos test para evaluar que el modelo es robusto y da resultados validos

No se encontró "todoDel1-7_page-0096.jpg".

No se encontró "todoDel1-7_page-0097.jpg".

Interpretation: Buscamos las conclusiones y buscamos en que podemos contribuir

No se encontró "todoDel1-7_page-0098.jpg".

Publishing and presentation: Buscamos difundir y facilitar el acceso a los resultados

No se encontró "todoDel1-7_page-0099.jpg".

No se encontró "todoDel1-7_page-0100.jpg".

No se encontró "todoDel1-7_page-0101.jpg".

No se encontró "todoDel1-7_page-0102.jpg".

No se encontró "todoDel1-7_page-0103.jpg".

No se encontró "todoDel1-7_page-0104.jpg".

No se encontró "todoDel1-7_page-0105.jpg".

No se encontró "todoDel1-7_page-0106.jpg".

No se encontró "todoDel1-7_page-0107.jpg".

No se encontró "todoDel1-7_page-0108.jpg".

No se encontró "todoDel1-7_page-0109.jpg".

No se encontró "todoDel1-7_page-0110.jpg".

No se encontró "todoDel1-7_page-0111.jpg".

No se encontró "todoDel1-7_page-0112.jpg".

No se encontró "todoDel1-7_page-0113.jpg".

No se encontró "todoDel1-7_page-0114.jpg".

No se encontró "todoDel1-7_page-0115.jpg".

No se encontró "todoDel1-7_page-0116.jpg".

No se encontró "todoDel1-7_page-0117.jpg".

No se encontró "todoDel1-7_page-0118.jpg".

No se encontró "todoDel1-7_page-0119.jpg".

No se encontró "todoDel1-7_page-0120.jpg".

No se encontró "todoDel1-7_page-0121.jpg".

No se encontró "todoDel1-7_page-0122.jpg".

En resumen es un modelo el cual usa los parametros para estimar un Y, es simple pero el modelo puede estar mal especificado

No se encontró "todoDel1-7_page-0123.jpg".

Buscan una estimación que se acerque lo más posible al dato, es flexible pero puede ser complejo

No se encontró "todoDel1-7_page-0124.jpg".

No se encontró "todoDel1-7_page-0125.jpg".

No se encontró "todoDel1-7_page-0126.jpg".

No se encontró "todoDel1-7_page-0127.jpg".

No se encontró "todoDel1-7_page-0128.jpg".

No se encontró "todoDel1-7_page-0129.jpg".

No se encontró "todoDel1-7_page-0130.jpg".

No se encontró "todoDel1-7_page-0131.jpg".

Las variables numericas usan regresiones lineales y las cualitativas usan regresion logistica.

No se encontró "todoDel1-7_page-0132.jpg".

No se encontró "todoDel1-7_page-0133.jpg".

No se encontró "todoDel1-7_page-0134.jpg".

No se encontró "todoDel1-7_page-0135.jpg".

No se encontró "todoDel1-7_page-0136.jpg".

No se encontró "todoDel1-7_page-0137.jpg".

No se encontró "todoDel1-7_page-0138.jpg".

No se encontró "todoDel1-7_page-0139.jpg".

No se encontró "todoDel1-7_page-0140.jpg".

No se encontró "todoDel1-7_page-0141.jpg".

No se encontró "todoDel1-7_page-0142.jpg".

No se encontró "todoDel1-7_page-0143.jpg".

No se encontró "todoDel1-7_page-0144.jpg".

No se encontró "todoDel1-7_page-0145.jpg".

No se encontró "todoDel1-7_page-0146.jpg".

No se encontró "todoDel1-7_page-0147.jpg".

No se encontró "todoDel1-7_page-0148.jpg".

No se encontró "todoDel1-7_page-0149.jpg".

No se encontró "todoDel1-7_page-0150.jpg".

No se encontró "todoDel1-7_page-0151.jpg".

No se encontró "todoDel1-7_page-0152.jpg".

No se encontró "todoDel1-7_page-0153.jpg".

No se encontró "todoDel1-7_page-0154.jpg".

No se encontró "todoDel1-7_page-0155.jpg".

No se encontró "todoDel1-7_page-0156.jpg".

No se encontró "todoDel1-7_page-0157.jpg".

No se encontró "todoDel1-7_page-0158.jpg".

Para explicarlo de la forma más sencilla posible, imagina que estás en la **cima de una montaña** y hay mucha niebla, por lo que no puedes ver el camino hacia el fondo del valle. Tu objetivo es llegar al punto más bajo (el **mínimo** de la función de error).

Así es como funciona el descenso por gradiente paso a paso:

1. **Siente la inclinación:** Como no ves el mapa completo, solo puedes sentir hacia dónde se inclina el suelo bajo tus pies. En matemáticas, esa inclinación es el **gradiente**.
2. **Da un paso hacia abajo:** Una vez que sabes hacia dónde está la bajada, das un paso en esa dirección. En el algoritmo, esto significa que **actualizas los parámetros** del modelo para que el error sea un poco más pequeño.
3. **El tamaño del paso (Tasa de aprendizaje):** Esto es qué tan grande es el salto que das.
 - Si el paso es **muy grande**, podrías pasarte de largo del fondo del valle.
 - Si el paso es **muy pequeño**, tardarás una eternidad en llegar.
4. **Repite hasta llegar al fondo:** Sigues dando pasos y volviendo a sentir la inclinación hasta que el suelo esté plano. En ese momento, habrás encontrado los **mejores parámetros** para tu modelo, donde el error es lo más bajo posible.

¿Por qué lo usamos?

A veces, calcular la solución perfecta de un solo viaje (la solución analítica) es como intentar teletransportarse: es demasiado pesado o imposible si tienes muchísimos datos. El descenso por gradiente es más eficiente porque va **aprendiendo poco a poco** a través de la práctica (iteraciones).

En resumen:

- **Función de costo:** Es la montaña (qué tan mal lo está haciendo el modelo).
- **Gradiente:** Es la dirección de la bajada.
- **Tasa de aprendizaje (α):** Es el tamaño de tus pasos.
- **Objetivo:** Llegar al lugar más bajo posible para que el modelo sea preciso.

No se encontró "todoDel1-7_page-0163.jpg".

No se encontró "todoDel1-7_page-0164.jpg".

No se encontró "todoDel1-7_page-0165.jpg".

No se encontró "todoDel1-7_page-0166.jpg".

No se encontró "todoDel1-7_page-0167.jpg".

No se encontró "todoDel1-7_page-0168.jpg".

No se encontró "todoDel1-7_page-0169.jpg".

No se encontró "todoDel1-7_page-0170.jpg".

No se encontró "todoDel1-7_page-0171.jpg".

No se encontró "todoDel1-7_page-0172.jpg".

No se encontró "todoDel1-7_page-0173.jpg".

No se encontró "todoDel1-7_page-0174.jpg".

No se encontró "todoDel1-7_page-0175.jpg".

No se encontró "todoDel1-7_page-0176.jpg".

No se encontró "todoDel1-7_page-0177.jpg".

No se encontró "todoDel1-7_page-0178.jpg".

No se encontró "todoDel1-7_page-0179.jpg".

No se encontró "todoDel1-7_page-0180.jpg".

No se encontró "todoDel1-7_page-0181.jpg".

No se encontró "todoDel1-7_page-0182.jpg".

No se encontró "todoDel1-7_page-0183.jpg".

No se encontró "todoDel1-7_page-0184.jpg".

No se encontró "todoDel1-7_page-0185.jpg".

No se encontró "todoDel1-7_page-0186.jpg".

No se encontró "todoDel1-7_page-0187.jpg".

No se encontró "todoDel1-7_page-0188.jpg".

No se encontró "todoDel1-7_page-0189.jpg".

No se encontró "todoDel1-7_page-0190.jpg".

No se encontró "todoDel1-7_page-0191.jpg".

No se encontró "todoDel1-7_page-0192.jpg".

No se encontró "todoDel1-7_page-0193.jpg".

No se encontró "todoDel1-7_page-0194.jpg".

No se encontró "todoDel1-7_page-0195.jpg".

No se encontró "todoDel1-7_page-0196.jpg".

No se encontró "todoDel1-7_page-0197.jpg".

No se encontró "todoDel1-7_page-0198.jpg".

No se encontró "todoDel1-7_page-0199.jpg".

No se encontró "todoDel1-7_page-0200.jpg".

No se encontró "todoDel1-7_page-0201.jpg".

No se encontró "todoDel1-7_page-0202.jpg".

No se encontró "todoDel1-7_page-0203.jpg".

No se encontró "todoDel1-7_page-0204.jpg".

No se encontró "todoDel1-7_page-0205.jpg".

No se encontró "todoDel1-7_page-0206.jpg".

No se encontró "todoDel1-7_page-0207.jpg".

No se encontró "todoDel1-7_page-0208.jpg".

No se encontró "todoDel1-7_page-0209.jpg".

No se encontró "todoDel1-7_page-0210.jpg".

No se encontró "todoDel1-7_page-0211.jpg".

No se encontró "todoDel1-7_page-0212.jpg".

No se encontró "todoDel1-7_page-0213.jpg".

No se encontró "todoDel1-7_page-0214.jpg".

Para explicarlo de la forma más sencilla posible, imagina que estás en la **cima de una montaña** y hay mucha niebla, por lo que no puedes ver el camino hacia el fondo del valle. Tu objetivo es llegar al punto más bajo (el **mínimo** de la función de error).

Así es como funciona el descenso por gradiente paso a paso:

1. **Siente la inclinación:** Como no ves el mapa completo, solo puedes sentir hacia dónde se inclina el suelo bajo tus pies. En matemáticas, esa inclinación es el **gradiente**.

2. **Da un paso hacia abajo:** Una vez que sabes hacia dónde está la bajada, das un paso en esa dirección. En el algoritmo, esto significa que **actualizas los parámetros** del modelo para que el error sea un poco más pequeño.
3. **El tamaño del paso (Tasa de aprendizaje):** Esto es qué tan grande es el salto que das.
 - Si el paso es **muy grande**, podrías pasarte de largo del fondo del valle.
 - Si el paso es **muy pequeño**, tardarás una eternidad en llegar.
4. **Repite hasta llegar al fondo:** Sigues dando pasos y volviendo a sentir la inclinación hasta que el suelo esté plano. En ese momento, habrás encontrado los **mejores parámetros** para tu modelo, donde el error es lo más bajo posible.

¿Por qué lo usamos?

A veces, calcular la solución perfecta de un solo viaje (la solución analítica) es como intentar teletransportarse: es demasiado pesado o imposible si tienes muchísimos datos. El descenso por gradiente es más eficiente porque va **aprendiendo poco a poco** a través de la práctica (iteraciones).

En resumen:

- **Función de costo:** Es la montaña (qué tan mal lo está haciendo el modelo).
- **Gradiente:** Es la dirección de la bajada.
- **Tasa de aprendizaje (α):** Es el tamaño de tus pasos.
- **Objetivo:** Llegar al lugar más bajo posible para que el modelo sea preciso.

No se encontró "todoDel1-7_page-0215.jpg".

No se encontró "todoDel1-7_page-0216.jpg".

No se encontró "todoDel1-7_page-0217.jpg".

No se encontró "todoDel1-7_page-0218.jpg".

No se encontró "todoDel1-7_page-0219.jpg".

No se encontró "todoDel1-7_page-0220.jpg".

No se encontró "todoDel1-7_page-0221.jpg".

No se encontró "todoDel1-7_page-0222.jpg".

No se encontró "todoDel1-7_page-0223.jpg".

No se encontró "todoDel1-7_page-0224.jpg".

No se encontró "todoDel1-7_page-0225.jpg".

No se encontró "todoDel1-7_page-0226.jpg".

No se encontró "todoDel1-7_page-0227.jpg".

No se encontró "todoDel1-7_page-0228.jpg".

No se encontró "todoDel1-7_page-0229.jpg".

No se encontró "todoDel1-7_page-0230.jpg".

No se encontró "todoDel1-7_page-0231.jpg".

No se encontró "todoDel1-7_page-0232.jpg".

No se encontró "todoDel1-7_page-0233.jpg".

No se encontró "todoDel1-7_page-0234.jpg".

No se encontró "todoDel1-7_page-0235.jpg".

No se encontró "todoDel1-7_page-0236.jpg".

No se encontró "todoDel1-7_page-0237.jpg".

No se encontró "todoDel1-7_page-0238.jpg".

No se encontró "todoDel1-7_page-0239.jpg".

No se encontró "todoDel1-7_page-0240.jpg".

No se encontró "todoDel1-7_page-0241.jpg".

No se encontró "todoDel1-7_page-0242.jpg".

No se encontró "todoDel1-7_page-0243.jpg".

No se encontró "todoDel1-7_page-0244.jpg".

No se encontró "todoDel1-7_page-0245.jpg".

No se encontró "todoDel1-7_page-0246.jpg".

No se encontró "todoDel1-7_page-0247.jpg".

No se encontró "todoDel1-7_page-0248.jpg".

No se encontró "todoDel1-7_page-0249.jpg".

No se encontró "todoDel1-7_page-0250.jpg".

No se encontró "todoDel1-7_page-0251.jpg".

No se encontró "todoDel1-7_page-0252.jpg".

No se encontró "todoDel1-7_page-0253.jpg".

No se encontró "todoDel1-7_page-0254.jpg".

No se encontró "todoDel1-7_page-0255.jpg".

No se encontró "todoDel1-7_page-0256.jpg".

No se encontró "todoDel1-7_page-0257.jpg".

No se encontró "todoDel1-7_page-0258.jpg".

No se encontró "todoDel1-7_page-0259.jpg".

No se encontró "todoDel1-7_page-0260.jpg".

No se encontró "todoDel1-7_page-0261.jpg".

No se encontró "todoDel1-7_page-0262.jpg".

No se encontró "todoDel1-7_page-0263.jpg".

No se encontró "todoDel1-7_page-0264.jpg".

No se encontró "todoDel1-7_page-0265.jpg".

No se encontró "todoDel1-7_page-0266.jpg".

No se encontró "todoDel1-7_page-0267.jpg".

No se encontró "todoDel1-7_page-0268.jpg".

Z-score

El **Z-score** (o estandarización) es una medida que indica cuántas desviaciones estándar se aleja un valor de la media. Según las fuentes, tiene dos aplicaciones principales:

- **Procesamiento de datos:** Se utiliza para normalizar variables, transformándolas para que tengan una media de cero y una desviación estándar de uno mediante la fórmula $x' = \frac{x - \mu}{\sigma}$.
- **Detección de valores atípicos:** Permite identificar *outliers* basándose en qué tan lejos se encuentra un punto del patrón general del conjunto de datos.
- **En regresión:** Se menciona que el Z-score (a menudo llamado **t-score** en este ámbito) mide cuántas desviaciones estándar está un coeficiente estimado (β^i) del valor cero.

t-value (o t-score)

El **t-value** es el estadístico de prueba utilizado específicamente en los modelos de regresión para determinar si un coeficiente es significativamente distinto de cero.

- **Cálculo:** Se obtiene dividiendo el coeficiente estimado (β^i) por su error estándar ($SE(\beta^i)$).

- **Interpretación:** Un valor de t alejado de cero (generalmente con un valor absoluto mayor a 2) sugiere que la variable tiene un efecto significativo sobre la variable de respuesta (y) y no es simplemente ruido. Si el valor es cercano a 0, el coeficiente no se considera significativo.

p-value

El **p-value** es la probabilidad de obtener un valor de t tan extremo como el observado, asumiendo que la hipótesis nula ($H_0: \beta_i = 0$) es cierta.

- **Interpretación:**
 - **p-valor pequeño ($p < 0.05$):** Indica que hay evidencia estadística suficiente para rechazar la hipótesis nula, lo que significa que la variable es **significativa** para el modelo.
 - **p-valor grande ($p > 0.05$):** Indica que no hay evidencia suficiente para afirmar que la variable influye en el resultado, por lo que podría ser irrelevante.
- **Uso gráfico:** Se visualiza como el área bajo la curva de la distribución t de Student en los extremos (colas) a partir del valor de t observado.

¿Para qué sirven en conjunto?

Estos indicadores son esenciales para la **selección de características (Feature Selection)**. Sirven para:

1. **Identificar variables relevantes:** Ayudan a decidir qué predictores deben mantenerse en el modelo y cuáles descartarse por ser redundantes o inútiles.
2. **Reducir el sobreajuste (overfitting):** Al eliminar variables no significativas basadas en su p -valor (como en el método de *Backward Selection*), se mejora la capacidad de generalización del modelo.
3. **Simplificar el modelo:** Permiten construir modelos más fáciles de interpretar y que requieren menos tiempo de entrenamiento.

No se encontró "todoDel1-7_page-0269.jpg".

No se encontró "todoDel1-7_page-0270.jpg".

No se encontró "todoDel1-7_page-0271.jpg".

No se encontró "todoDel1-7_page-0272.jpg".

No se encontró "todoDel1-7_page-0273.jpg".

No se encontró "todoDel1-7_page-0274.jpg".

No se encontró "todoDel1-7_page-0275.jpg".

No se encontró "todoDel1-7_page-0276.jpg".

No se encontró "todoDel1-7_page-0277.jpg".

No se encontró "todoDel1-7_page-0278.jpg".

No se encontró "todoDel1-7_page-0279.jpg".

No se encontró "todoDel1-7_page-0280.jpg".

No se encontró "todoDel1-7_page-0281.jpg".

No se encontró "todoDel1-7_page-0282.jpg".

No se encontró "todoDel1-7_page-0283.jpg".

No se encontró "todoDel1-7_page-0284.jpg".

No se encontró "todoDel1-7_page-0285.jpg".

Unidad 2



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA


Visualización de Datos para el Análisis Exploratorio

Jorge Portilla


Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

**Leverage the power of graphs GPUs to visualize, analyze,
and scale your data**

<https://www.graphistry.com>



De visualizar puntos a visualizar ecosistemas completos




⁴ NVIDIA Deep Learning Institute course "Fundamentals of Accelerated Data Science" (Course ID: C-DS-02-V2), NVIDIA Corporation. Available: https://learn.nvidia.com/courses/course-detail?course_id=course-v1:DLI+C-DS-02+V2. Accessed : May25, 2026.



Graphs, e utiliza para recopilar información sobre las relaciones entre objetos

KNOWLEDGE GRAPHS



SOCIAL NETWORKS & RECOMMENDER SYSTEMS




Casos de uso de datos de grafos

Healthcare




Connectomes
Brain fMRI/DTI

Chemistry & Pharmacy




Molecular Analysis
Drug Discovery
Drug Repurposing

Financial Soundness Indicators




Stock Market Prediction

Physics



Particle Systems
Thermodynamics


Graph



Visualisation of high dimensional data using t-SNE



Principal component analysis




The Curse of Dimensionality - examples

"Netflix dataset (in 3D) on Russ's RBM features"

representa datos de calificaciones de usuarios proyectados en un espacio tridimensional. Las características fueron extraídas mediante una Restricted Boltzmann Machine (RBM) entrenada por Russ Salakhutdinov, capturando patrones latentes en las preferencias de los usuarios. La visualización muestra cómo las películas y usuarios se organizan en función de sus relaciones implícitas, destacando la estructura del dataset de recomendaciones.


<https://lvdmaaten.github.io/tsne/>



The Curse of Dimensionality - examples



"Words (in 2D) by Joseph on features learned by Ronan and Jason" representa palabras proyectadas en 2D desde un espacio de alta dimensionalidad. Estas características fueron aprendidas mediante modelos de embeddings de palabras, capturando relaciones semánticas y sintácticas en un corpus de texto. La visualización ilustra cómo palabras con significados similares tienden a agruparse, reflejando la estructura latente del lenguaje. <https://lvdmaaten.github.io/tsne/>



The Curse of Dimensionality - examples



The Curse of Dimensionality




3

- *Curse of dimensionality* surge cuando se analizan datos en espacios de alta dimensión.
- En la derecha, una variable con 10 regiones de interés. Con suficientes ejemplos los [algoritmos de aprendizaje](#) pueden generalizar correctamente.
- Se requieren exponencialmente más datos para cubrir todas las posibles configuraciones (datos dispersos dificulta la generalización).

³Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press.

Necesidades de aplicaciones modernas



Original data up to the year 2010 collected and plotted by M. Horowitz, F. Labonte, O. Shacham, K. Olukotun, L. Hammond, and C. Batten New plot and data collected for 2010-2015 by K. Rupp

²NVIDIA Deep Learning Institute course "Fundamentals of Accelerated Data Science" (Course ID: C-DS-02-V2), NVIDIA Corporation. Available: https://learn.nvidia.com/courses/course-detail?course_id=course-v1:DLI+C-DS-02+V2. Accessed: May 25, 2026.

Data science es la clave para abrir las puertas al futuro de los negocios modernos



Retail

Supply Chain & Inventory Management
Price Management / Markdown Optimization
Promotion Prioritization And Ad Targeting



Telecom

Detect Network/Security Anomalies
Forecasting Network Performance
Network Resource Optimization (RSON)



Healthcare

Improve Clinical Care
Drive Operational Efficiency
Speed Up Drug Discovery



Manufacturing

Remaining Useful Life Estimation
Failure Prediction
Demand Forecasting




Financial Services

Claim Fraud
Customer Service Chatbots/Routing
Risk Evaluation



Consumer Internet

Ad Personalization
Click Through Rate Optimization
Churn Reduction



Oil & Gas

Sensor Data Tag Mapping
Anomaly Detection
Robust Fault Prediction



Automotive

Personalization & Intelligent Customer Interactions
Connected Vehicle Predictive Maintenance
Forecasting, Demand, & Capacity Planning

¹ NVIDIA Deep Learning Institute course "Fundamentals of Accelerated Data Science" (Course ID: C-DS-02-V2), NVIDIA Corporation. Available:
https://learn.nvidia.com/courses/course-detail?course_id=course-v1:DLI+C-DS-02+V2. Accessed: May 25, 2026.

- **Fundamentos de Visualización**
 - Percepción humana y criterios de diseño
 - Distracciones y efectividad visual
- **Técnicas de Reducción de Dimensionalidad**
 - Datos de alta dimensionalidad
 - Métodos de agrupación y exploración
- **Técnicas de visualización de datos para el análisis de datos.**
 - Análisis de textos
 - Clasificación y predicción
 - Series de tiempo
 - Procesamiento y visualización de imágenes
 - Interfaz gráfica de usuario



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Visualización de Datos para el Análisis Exploratorio

Jorge Portilla

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

K-nearest Neighbors and K-means Algorithms

EIN087B - Ciencia de Datos
Paralelo 701

Profesor: Jorge Portilla G.
jorge.portilla@usm.cl

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

- ▶ Algoritmo de **aprendizaje supervisado** para problemas de **regresión**.
- ▶ Predice el valor de una muestra basándose en los valores de sus k vecinos más cercanos.

Pasos para KNN Regressor

- ▶ Se calcula la distancia entre el punto de interés y los puntos del conjunto de entrenamiento.
- ▶ Se seleccionan los k puntos más cercanos.
- ▶ El **valor predicho** es la **media** (o una combinación) de los valores de esos k vecinos más cercanos.
 - Un k pequeño puede captar más **ruido**.
 - Un k grande puede hacer la predicción demasiado **general**.
- ▶ La distancia **euclidiana** es la más común, pero también se pueden usar otras como **Manhattan** o **Minkowski**.

Los algoritmos KNN, buscan en una plano de n dimensiones los puntos mas cercanos y les calcula la media

- ▶ **KNN es costoso computacionalmente.**
- ▶ Conforme la dimensionalidad y la escala del dataset aumenta, el tamaño del modelo aumenta, lo que impacta el rendimiento y complejidad del modelo.
- ▶ KNN es sensible a los outliers por lo que pequeños cambios en los datos de entrada (noise) pueden afectar el rendimiento del modelo.

El KNN es costoso y requiere limpieza de outliers

► Valor de k bajo:


- Un k bajo (e.g., 1 o 2) hace que el modelo sea muy sensible a los **outliers**.
- Los **outliers** son instancias extremas que no siguen las tendencias generales del conjunto de datos.
- Como resultado, las predicciones del modelo se vuelven inestables.

► Valor de k alto:

- A medida que aumenta k , se observa un aumento inicial en la estabilidad del algoritmo.
- Con más vecinos, el efecto de los outliers disminuye debido al voto mayoritario.
- Sin embargo, al seguir aumentando k , la estabilidad comienza a disminuir y la precisión del modelo se deteriora.

Menor dataset = menor k = mas sensible al ruido y outliers

mayor dataset = mas k = mas general




Como podemos ver, el valor de $k = 1$ tiene el mayor accuracy. Pero, para $k = 1$, el modelo será muy sensible a los outliers. Por lo tanto, optaremos por $k = 12$, que tiene el segundo mejor accuracy (0.59) .

- ▶ **Paso 1:** Guardar el dataset en la memoria (**equivalente al entrenamiento**). Dividir el dataset en training y test set.
- ▶ **Paso 2:** Inferencia en el algoritmo KNN: el proceso de cálculo de la distancia es un proceso iterativo en el que calculamos la distancia euclidiana de un punto de datos en los datos de prueba con respecto a cada punto de datos en los datos de entrenamiento.
- ▶ **Paso 3:** $d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2 + (z_2 - z_1)^2}$.
- ▶ Selecciona los k puntos de datos de entrenamiento más cercanos al punto de datos de prueba, basándose en las distancias calculadas. **La etiqueta con la mayor frecuencia de aparición se asigna como clase objetivo al punto de datos de prueba.**

- Para prevenir inestabilidades en el proceso de entrenamiento, estandarizamos el tensor de entrada $\mathbf{X}$ y el tensor de salida $\mathbf{Y}$ que contienen todos los pares de imágenes de entrada-salida de entrenamiento:

$$\bar{\mathbf{X}} = \frac{\mathbf{X} - \mu_{\mathbf{X}}}{\sigma_{\mathbf{X}}}, \quad \bar{\mathbf{Y}} = \frac{\mathbf{Y} - \mu_{\mathbf{Y}}}{\sigma_{\mathbf{Y}}} \quad (3)$$

- Ninguna muestra de vino recibe una calificación superior a 8 ni inferior a 3⁶⁷. Estos casos pueden considerarse una situación hipotéticamente ideal, o probablemente esos datos sufren un sampling bias.




⁶ StratifiedKFold

⁷ AUC-ROC ó vecinos más cercanos con más influencia usando la inversa de la distancia


- ▶ **UCI Red Wine Dataset:** Contiene 1,599 muestras de vino tinto.
- ▶ El objetivo es predecir la **calidad del vino**, que es una variable ordinal en una escala de 0 a 10.
- ▶ **Variables del Dataset:**
 - **Fixed acidity:** Acidez fija (no volátil).
 - **Volatile acidity:** Acidez volátil (afecta al aroma).
 - **Citric acid:** Ácido cítrico (contribuye a la frescura).
 - **Residual sugar:** Azúcar residual (después de la fermentación).
 - **Chlorides:** Nivel de sal.
 - **Free sulfur dioxide:** Sulfuro de dióxido libre (conservante).
 - **Total sulfur dioxide:** Dióxido de azufre total.
 - **Density:** Densidad del vino.
 - **pH:** Mide la acidez.
 - **Sulphates:** Sulfatos (conservante).
 - **Alcohol:** Contenido de alcohol en el vino.

- ▶ `K-Neighbors Classifier` maneja un parámetro para identificar la métrica de distancia, llamado *metric*, el cual por defecto tiene como valor la distancia de **Minkowski**.
- ▶ `K-NeighborsClassifier` maneja un parámetro **p** para definir la **potencia** aplicada a la métrica distancia de Minkowski, siendo su valor por defecto $p = 2$.
- ▶ ¿Qué valor debiéramos configurar para p ?




- El enfoque KNN, utilizando $K=3$, se ilustra en una situación simple con seis observaciones azules y seis observaciones naranjas.
- **Izquierda:** Se muestra una observación de prueba, donde se desea predecir una etiqueta de clase. Se identifican los tres puntos más cercanos a la observación de prueba, y se predice que la observación de prueba pertenece a la clase que ocurre con mayor frecuencia (azul).
- **Derecha:** Se muestra la frontera de decisión del KNN para este ejemplo en negro.

Funcionamiento Merge Sort




Funcionamiento Bubble Sort




⁵Diego Hernán Hidalgo Contreras, Diseño e implementación del algoritmo K-Nearest Neighbors en FPGA para clasificación binaria (Tesis de Grado, Ingeniería de Ejecución en Control e Instrumentación Industrial, UTFSM, 2025)

Funcionamiento del algoritmo k-NN



Ejemplo de KNN Classifier



Para visualizar problemas con más de 2 o 3 dimensiones, se recomienda usar PCA.

Aquí estamos usando KNN para encontrar a qué etiqueta pertenece el dato, en este caso es class B

Definición de KNN:

- ▶ Dado un entero positivo K y una observación de prueba x_0 , el clasificador KNN identifica los K puntos más cercanos en los datos de entrenamiento.
- ▶ Estos puntos más cercanos se representan como $\mathcal{N}_0$.
- ▶ La probabilidad condicional estimada para la clase j se calcula como la fracción de puntos en $\mathcal{N}_0$ cuyas respuestas corresponden a la clase j :

$$\Pr(Y = j \mid X = x_0) = \frac{1}{K} \sum_{i \in \mathcal{N}_0} I(y_i = j).$$

- ▶ Aquí, $\mathcal{N}_0$ representa el conjunto de los K puntos más cercanos a la observación de prueba x_0 , e $I(y_i = j)$ es una función indicadora⁴ que es 1 si $y_i = j$ y 0 en caso contrario.
- ▶ **Clasificación:** KNN clasifica la observación de prueba x_0 a la clase con la mayor probabilidad estimada, de acuerdo con la ecuación anterior.

⁴ Métricas de distancia

Definición de KNN:

- ▶ Dado un entero positivo K y una observación de prueba x_0 , el clasificador KNN identifica los K puntos más cercanos en los datos de entrenamiento.
- ▶ Estos puntos más cercanos se representan como $\mathcal{N}_0$.

⁴ Métricas de distancia

$\mathcal{N}_0 =$ es el punto mas cercano

- ▶ **Objetivo de KNN:** Predecir respuestas cualitativas (clasificación) a partir de la proximidad a los puntos de entrenamiento conocidos.
- ▶ El clasificador KNN intenta aproximar la distribución condicional de Y dado X sin asumir un modelo paramétrico
- ▶ **Ventajas:**
 - No requiere suposiciones sobre la distribución de los datos.
 - Es simple y fácil de entender.
- ▶ **Desventajas:**
 - Sensible al valor de K y a la métrica de distancia utilizada.
 - Computacionalmente costoso para grandes datasets.

- ▶ **Cálculo de la distancia:** El modelo KNN calcula la distancia³ entre el nuevo punto de datos y todos los puntos de datos en el conjunto de datos de entrenamiento.
- ▶ **Selección de vecinos más cercanos:** El algoritmo selecciona un número k de puntos de datos de entrenamiento más cercanos al nuevo punto de datos.
- ▶ **Asignación de la clase:** El algoritmo asigna al nuevo punto de datos la clase que aparece con mayor frecuencia entre estos k vecinos.

³Distancia euclidiana

- ▶ KNN es un algoritmo no paramétrico. Por lo tanto, el entrenamiento de un clasificador KNN no requiere recurrir al enfoque más tradicional de iterar sobre los datos de entrenamiento durante varias épocas para optimizar un conjunto de parámetros.
- ▶ El entrenamiento de KNN implica almacenar todas las instancias de entrenamiento en la memoria del equipo simultáneamente.
- ▶ Etapa de inferencia: el modelo compara estos nuevos datos con las instancias de entrenamiento existentes.

KNN es **no paramétrico y no requiere entrenamiento iterativo**, si no solo guardar datos en memoria

- ▶ El algoritmo KNN es uno de los algoritmos clásicos de aprendizaje automático supervisado.
- ▶ KNN es capaz de clasificar tanto en binario como en multiclase.
- ▶ Algoritmo de clasificación no paramétrico. No paramétrico por naturaleza, KNN también puede utilizarse como algoritmo de regresión.

KNN tambien sirve para multiclase y puede servir como algoritmo regresivo

K-Nearest Neighbors

La actualización de centroides en MiniBatchMeans se realiza utilizando la siguiente fórmula:

$$C_{t+1} = C_t + \frac{1}{N_i}(x_i - C_t)$$

- ▶ x_i : Es el punto de datos del mini-batch actual asignado al centroide. Representa un vector de características del conjunto de datos.
- ▶ C_t : Es la posición actual del centroide en la iteración t .
- ▶ C_{t+1} : Es la nueva posición del centroide después de la actualización en la iteración $t + 1$.
- ▶ N_i : Es el número de puntos asignados al centroide C hasta la iteración i .
- ▶ Se ajusta el centroide C_t a partir de la información del punto x_i del mini-batch, moviéndolo ligeramente hacia x_i para que el centroide se acerque más a los puntos asignados a él.
- ▶ Este ajuste es incremental, lo que significa que el cambio en el centroide se vuelve más pequeño a medida que se procesan más puntos, estabilizando la posición del centroide con el tiempo.

La actualización de centroides en MiniBatchMeans se realiza utilizando la siguiente fórmula:

$$C_{t+1} = C_t + \frac{1}{N_i}(x_i - C_t)$$

- ▶ x_i : Es el punto de datos del mini-batch actual asignado al centroide. Representa un vector de características del conjunto de datos.
- ▶ C_t : Es la posición actual del centroide en la iteración t .
- ▶ C_{t+1} : Es la nueva posición del centroide después de la actualización en la iteración $t + 1$.
- ▶ N_i : Es el número de puntos asignados al centroide C hasta la iteración i .


K-means vs. MiniBatchMeans (2)



- ▶ Por lo general, MiniBatchKMeans produce resultados de menor desempeño que los del algoritmo estándar.
- ▶ Se extraen muestras aleatorias del dataset (mini-batch).
- ▶ Estas muestras se asignan al centroide más cercano.
- ▶ Los centroides se actualizan, pero, a diferencia de K-Means, se actualizan por muestra.
- ▶ Para cada muestra del mini-batch, el centroide asignado se actualiza tomando el promedio acumulado de la muestra y de todas las muestras anteriores asignadas a ese centroide. Esto reduce la tasa de cambio del centroide con el tiempo.
- ▶ **Criterio de parada:** Los pasos se repiten hasta que se alcanza la convergencia o se alcanza un número predeterminado de iteraciones.

Usa muestra aleatorias para crear el centroide de datos o sea las clasificaciones

K-means vs. MiniBatchMeans




- ▶ **MiniBatchKMeans** es una variante del algoritmo K-Means que utiliza mini-batches para reducir el tiempo de cálculo.
- ▶ Aunque reduce el tiempo de cálculo, sigue intentando optimizar la misma función objetivo que el K-Means estándar.
- ▶ **Mini-batches:** Son subconjuntos de los datos de entrada, muestreados aleatoriamente en cada iteración de entrenamiento.
- ▶ **Ventaja:** Los mini-batches reducen drásticamente la cantidad de cálculo necesario para converger a una solución local.
- ▶ **Criterio de parada:** Los pasos se repiten hasta que se alcanza la convergencia o se alcanza un número predeterminado de iteraciones.

Es mas eficiente

- ▶ K-means estándar puede ser computacionalmente costoso y lento en datasets grandes debido a la necesidad de recalcular los centroides en cada iteración sobre todos los datos.
- ▶ **Método:**
 - En lugar de usar el conjunto de datos completo en cada iteración, MiniBatchKMeans toma mini-batches de datos de forma aleatoria.
 - Actualiza los centroides únicamente a partir del mini-lote actual, lo que reduce drásticamente el tiempo de cálculo.

K-means clustering on the digits dataset (PCA-reduced data)
Centroids are marked with white cross



A demo of K-Means clustering on the handwritten digits data

init	time	inertia	homo	compl	v-meas	ARI	AMI	silhouette
k-means++	0.050s	69545	0.598	0.645	0.621	0.469	0.617	0.152
random	0.064s	69735	0.681	0.723	0.701	0.574	0.698	0.170
PCA-based	0.017s	69513	0.600	0.647	0.622	0.468	0.618	0.162

- ▶ **v-meas:** La media armónica de homogeneidad y completitud, una medida equilibrada entre ambas.
- ▶ **ARI (Adjusted Rand Index):** Una medida que compara la similitud entre las agrupaciones generadas por el algoritmo y una agrupación de referencia, ajustada por la probabilidad de coincidencias aleatorias.
- ▶ **AMI (Adjusted Mutual Information):** Indica qué tan similares son las agrupaciones producidas por el algoritmo a una clasificación esperada, ajustada por la probabilidad de coincidencias aleatorias.
- ▶ **silhouette:** Un índice que mide qué tan similares son los puntos a su propio cluster en comparación con otros clusters, con valores entre -1 y 1 (cercano a 1 es mejor).

init	time	inertia	homo	compl	v-meas	ARI	AMI	silhouette
k-means++	0.050s	69545	0.598	0.645	0.621	0.469	0.617	0.152
random	0.064s	69735	0.681	0.723	0.701	0.574	0.698	0.170
PCA-based	0.017s	69513	0.600	0.647	0.622	0.468	0.618	0.162


- ▶ **time:** El tiempo que tarda en ejecutarse el algoritmo.
- ▶ **inertia:** Suma de las distancias al cuadrado entre los puntos de datos y sus centroides.
- ▶ **homo (homogeneidad):** Mide qué tan homogéneos son los clusters; es decir, qué tan bien un solo cluster contiene únicamente puntos de una sola clase.
- ▶ **compl (completitud):** Mide qué tan completos son los clusters; es decir, qué tan bien todos los puntos de una clase se encuentran dentro del mismo cluster.
- ▶ **v-meas:** La media armónica de homogeneidad y completitud, una medida equilibrada entre ambas.


```
1 from sklearn.cluster import KMeans
2 from sklearn.decomposition import PCA
3 kmeans = KMeans(init="k-means++", n_clusters=n_digits,
4                 n_init=4, random_state=0)
5 bench_k_means(kmeans=kmeans, name="k-means++", data=data,
6               labels=labels)
7
8 kmeans = KMeans(init="random", n_clusters=n_digits,
9                 n_init=4, random_state=0)
10 bench_k_means(kmeans=kmeans, name="random", data=data,
11               labels=labels)
12
13 pca = PCA(n_components=n_digits).fit(data)
14 kmeans = KMeans(init=pca.components_, n_clusters=n_digits,
15                 n_init=1)
16 bench_k_means(kmeans=kmeans, name="PCA-based", data=data,
17               labels=labels)
```

*n_init: number of times the k-means algorithm is run with different centroid seeds.

- ▶ Compararemos tres enfoques:
 - **Una inicialización usando k-means++.** Este método es estocástico, y ejecutaremos la inicialización 4 veces.
 - **Una inicialización aleatoria.** Este método también es estocástico, y ejecutaremos la inicialización 4 veces.
 - **Una inicialización basada en una proyección PCA.** Usaremos los componentes de la PCA para inicializar KMeans. Este método es determinista y una sola inicialización es suficiente.

- ▶ En este ejemplo, comparamos las diferentes estrategias de inicialización para K-means en términos de tiempo de ejecución y calidad de los resultados.





- ▶ **Nombre:** Dígitos Escritos a Mano (Handwritten Digits)
- ▶ **Imágenes:** 1797 imágenes de 8x8 píxeles
- ▶ **Clases:** 10 (dígitos del 0 al 9)
- ▶ **Etiquetas:** Cada imagen está etiquetada con el dígito correspondiente
- ▶ **Objetivo:** Clasificar correctamente las imágenes en una de las 10 categorías
- ▶ **Desafíos:** Variabilidad en la escritura a mano y similitud entre ciertos dígitos

En un conjunto de datos con puntos muy dispersos, k-means++ se enfoca en que los primeros centroides estén en diferentes partes del espacio de datos, mientras que el k-means puede seleccionar varios centroides muy cercanos entre sí, lo que puede llevar a un rendimiento deficiente.

- ▶ Después de seleccionar el primer centroide al azar, los siguientes centroides se seleccionan utilizando una probabilidad proporcional.
- ▶ Para cada punto x , se calcula la distancia $D(x)$ al centroide más cercano ya seleccionado.
- ▶ El siguiente centroide se selecciona con probabilidad proporcional a $D(x)^2$, es decir:

$$P(x) = \frac{D(x)^2}{\sum_{x \in \text{datos}} D(x)^2}$$

- ▶ Esto significa que los puntos más alejados de los centroides seleccionados tienen una mayor probabilidad de ser elegidos como nuevos centroides.

K-means++ elige punto mas apartados entre si para sus centrides de esa manera los centroides estan apartados

- ▶ **Problema Clásico en K-means:** La calidad del clustering en K-means depende fuertemente de la inicialización de los centroides. Una mala inicialización puede conducir a soluciones subóptimas o a la convergencia en mínimos locales.
- ▶ **K-means++**
 - Introducido para mejorar la robustez del K-means.
 - Elegir centroides iniciales que estén óptimamente distanciados entre sí.
 - Selecciona el primer centroide de manera aleatoria.
 - Para cada punto restante, selecciona un nuevo centroide con una probabilidad proporcional al cuadrado de la distancia mínima a cualquier centroide ya elegido.
 - Repite hasta que se hayan seleccionado K centroides.

K-means depende mucho de la selección de centroides





Figura 1: K-means clustering elbow



- El **método del codo** es una técnica común para **identificar el K óptimo**, buscando el punto en el que la disminución de la inercia deja de ser tan pronunciada.
- Sum of Squared Errors (SSE).

El metodo del codo usca la cantidad optima de cluster lo suficiente para no tener tanto errores, pero menos que para hacer overfitting

- ▶ **Valores Bajos de Inercia:** Indican que los puntos dentro de un cluster están cerca de su centroide.
- ▶ **Valores Altos de Inercia:** Pueden indicar que los puntos no están bien agrupados o que hay mucha dispersión dentro de los clusters.
- ▶ Al evaluar diferentes valores de K (número de clusters), los modelos con menor inercia suelen considerarse mejores, ya que implican clusters más compactos.

La suma de distancias al cuadrado se define matemáticamente como:

$$SSE = \sum_{i=1}^n \min_{c \in \{1, \dots, K\}} \|x_i - \mu_c\|^2$$


donde:

- ▶ n es el número de puntos de datos.
- ▶ K es el número de clusters.
- ▶ x_i es el vector de características del punto de datos i .
- ▶ μ_c es el centroide del cluster c .
- ▶ $\|x_i - \mu_c\|^2$ es la distancia al cuadrado entre el punto de datos i y el centroide c .

- ▶ `kmeans.inertia_` es un atributo de un objeto K-Means en `scikit-learn` que representa la suma de las distancias al cuadrado del modelo de clustering K-means.
- ▶ La inercia es la suma de los cuadrados de las distancias de cada punto de datos a su centroide más cercano.
- ▶ Es una medida de qué tan bien se agrupan los puntos dentro de sus respectivos clústeres.


La **inercia** es un valor de que tan bien agrupados es tan los valores del cluster respecto al centroide

5. **Paso 5:** Repetir pasos 3 y 4 hasta que los centroides no cambien.




4. Paso 4: Asignar cada punto de datos al cluster más cercano.

- ▶ Se recalcula los centroides de cada cluster z_3 tomando la media de los puntos asignados a ese cluster.
- ▶ Se inicializa una matriz de centroides y se calcula la media de los puntos en ese cluster, actualizando la posición del centroide.
- ▶ Se repite hasta que los centroides se estabilizan, permitiendo que los clusters converjan a su forma final.



3. **Paso 3:** Asignar cada punto de datos al cluster más cercano.


- ▶ Se inicializa una lista de clusters vacíos y luego, para cada punto en el conjunto de datos **X**.
- ▶ Se calcula la distancia euclidiana desde ese punto hasta cada uno de los centroides



K-means

Dado un dataset sintético creado con `make_blobs` que contiene 1000 ejemplos, 2 características y clusters.

1. **Paso 1:** K igual a 3.
2. **Paso 2:** Inicializar los centroides aleatoriamente².




²Selecciona 3 ejemplos de los datos.

- ▶ **Clustering** es el proceso de dividir todo el conjunto de datos en grupos basados en los patrones observados en él.
- ▶ El objetivo principal del algoritmo K-Means es minimizar la suma de las distancias entre los puntos y sus respectivos centroides de clúster.

Pasos del Algoritmo K-Means:

1. Elegir el número de clústeres k .
2. Seleccionar k puntos aleatorios del conjunto de datos como centroides.
3. Asignar todos los puntos al centroide del clúster más cercano.
4. Recalcular los centroides de los clústeres recién formados.
5. Repetir los pasos 3 y 4 hasta que los centroides no cambien.

el cluster divide en conjuntos el dataset, hay que minimizar las distancia



- ▶ **K-means clustering** es una técnica en la que colocamos cada observación en un conjunto de datos en uno de K clusters.
- ▶ El objetivo es tener K clusters agrupando las observaciones similares entre sí.
- ▶ En la práctica, utilizamos los siguientes pasos para realizar K-means clustering:

K-means

► Caso cuando $p \rightarrow \infty$:

- Considere $a = |x_2 - x_1|$ y $b = |y_2 - y_1|$.
- Si $p \rightarrow \infty$, entonces $a^p + b^p$ estará dominado por el mayor de los dos términos.
- Suponiendo que $a \geq b$, entonces $a^p + b^p \approx a^p$ cuando p es muy grande.

► Límite:

$$d_{\infty} = \lim_{p \rightarrow \infty} (a^p + b^p)^{\frac{1}{p}} \approx \lim_{p \rightarrow \infty} (a^p)^{\frac{1}{p}} = a$$

► Resultado:

- Cuando $p \rightarrow \infty$, $d_{\text{minkowski}}$ se convierte en $\max(a, b)$, que es la **Distancia de Chebyshev**.


Distancia de Minkowski:

es una generalización de las distancias Euclidiana y Manhattan. Se calcula la distancia de Minkowski entre los puntos P_1 y P_2 con un parámetro p utilizando la expresión:

$$d_{\text{minkowski}} = (|x_2 - x_1|^p + |y_2 - y_1|^p)^{\frac{1}{p}} \quad (2)$$

Dependiendo del valor de p :



- Si $p = 1$, se obtiene la distancia Manhattan.
- Si $p = 2$, se obtiene la distancia Euclidiana.
- Si $p = \infty$, se obtiene la distancia Chebyshev.



Cuando el parámetro p tiende a infinito, se define como el máximo de las diferencias absolutas entre las coordenadas de dos puntos.



¹Fu, C., Yang, J. (2021). Granular classification for imbalanced datasets: a minkowski distance-based method. Algorithms, 14(2), 54.

Distancia de Minkowski



$$d_{\text{minkowski}} = (|x_2 - x_1|^p + |y_2 - y_1|^p)^{\frac{1}{p}} \quad (1)$$

Distancia de Minkowski





UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

K-nearest Neighbors and K-means Algorithms

EIN087B - Ciencia de Datos
Paralelo 701

Profesor: Jorge Portilla G.
jorge.portilla@usm.cl

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile