

Ciencia de datos

Procesamiento y visualización de datos

- variable: característica que se mide u observa en un conjunto de datos
- Observación: conjunto de valores que se registran para una variable en particular
- Distribución: característica o atributo que se mide
- Correlación: relación entre datos

Tipo de datos

Datos estructurados

ID Paciente	Nombre	Apellido	Fecha de Nacimiento	Sexo	Dirección	Teléfono
1	Juan	Pérez	01/01/1990	H	Av. Libertad 123	555-1234
2	María	García	02/02/1992	M	Calle 45 #23	555-5678
3	Pedro	Rodríguez	03/03/1995	H	Av. Independencia 456	555-9012
4	Ana	Sánchez	04/04/1991	M	Calle 12 #56	555-1111

Datos no estructurados

Nombre: Juan Pérez
Edad: 35
Sexo: Masculino
Diagnóstico: Diabetes tipo 2
Medicamentos: - Metformina - Insulina
Alergias: - Penicilina

Archivos JSON y XML.

Datos semi-estructurados

Fuente de datos

registro, sensores, bases de datos, investigaciones, métodos de consulta,etc. Todos esos son métodos para obtener datos.



Procesamiento de datos

Problema de datos:

- Valores faltantes o duplicados
- Valores inconsistentes
- Ruido
- Errores de formato

Técnica y herramientas:

- Eliminación y/o remplazo de datos faltantes
- Corrección de formato
- Eliminación de duplicados

Normalización

Escalado máximo-mínimo (Min-Max)

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Z-score (Estandarización)

$$x' = \frac{x - \mu}{\sigma}$$

Normalización máxima (Max Norm)

$$x' = \frac{x}{x_{\max}}$$

Transformación de variables

Codificación One-Hot

Ejemplo: Rojo $\rightarrow (1,0,0)$, Azul $\rightarrow (0,1,0)$

Codificación ordinal

Ejemplo: Bajo (1), Medio (2), Alto (3)

Discretización de variables numéricas

Ejemplo: $[0, 10] \rightarrow$ "bajo", $[11, 20] \rightarrow$ "medio"

Medida de tendencia central y dispersión

Media
(promedio)

Media aritmética:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

Promedio de los valores de un conjunto de datos.


Desviación
estándar

Fórmula:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

Mide la dispersión de los datos respecto a la media.

Restar la media o estandarizar: Al restar μ_x a los datos se centra el espacio en las medias, por lo que la media de los datos estandarizados es cero ($\mu_x = E[x] = 0$)



- **Varianza:** medida que indica qué tan dispersos están los valores con respecto a la media.


$$\text{var}(x) = \sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$$

- **Covarianza:** representa la tasa de cambio entre dos variables aleatorias.

$$\text{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)(y_i - \mu_y)$$

- **Correlación:** mide la relación lineal entre dos variables, estandarizando la covarianza.

$$\text{Corr}(x, y) = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$



Sea el vector $\mathbf{x} = \{x_1, \dots, x_N\}$, un vector de variables aleatorias.

$$\mathbf{C}_x = \mathbf{C}_x^{N \times N} = (c_{ij} | c_{ij} = \text{Cov}(x_i, x_j))$$

Teniendo en cuenta que $\text{Cov}(x, x) = \sigma_x^2$ y sea $\mathbf{x} = \{x, y, z\}$:


$$\mathbf{C}_x = \begin{pmatrix} \sigma_x^2 & \text{Cov}(x, y) & \text{Cov}(x, z) \\ \text{Cov}(x, y) & \sigma_y^2 & \text{Cov}(y, z) \\ \text{Cov}(x, z) & \text{Cov}(y, z) & \sigma_z^2 \end{pmatrix}$$

- $\mathbf{C}_x$ es una matriz simétrica.
- La matriz de covarianza también se puede definir como:

$$\mathbf{C}_x = E[(\mathbf{x} - \mu_x)(\mathbf{x} - \mu_x)^T] = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k \mathbf{x}_k^T - \mu_x \mu_x^T)$$

► **Escala:**

- La covarianza depende de las unidades de las variables.
- La correlación es adimensional, normalizada entre -1 y 1.




► **Comparabilidad:**

- La covarianza no es directamente comparable entre distintos pares de variables.
- La correlación permite comparaciones directas entre diferentes pares de variables.

Detección de Outliers (Valores Atípicos)


Son datos que se desvían significativamente del patrón general de un conjunto de datos. Pueden ser causados por errores de medición, variabilidad natural o eventos excepcionales.



- **Método de la Distancia:** Identifica outliers basados en la distancia a la media o a otros puntos de datos (e.g., Z-score).
- **Método de la Densidad:** Detecta outliers como puntos con baja densidad de vecinos (e.g., DBSCAN).
- **Otros Métodos:** Incluyen métodos basados en modelos estadísticos, métodos de aprendizaje automático (e.g., Isolation Forest), etc.

19

Outliers



20

- ▶ **Mediana (Línea Amarilla):** Valor central, divide los datos en 50/50.
- ▶ **Caja (IQR):** Rango intercuartílico (Q1 a Q3), 50 % central de los datos.
 - Q1: 25 % de los datos por debajo.
 - Q3: 75 % de los datos por debajo.
- ▶ **Líneas "Mínimo" "Máximo":** Límites de datos no atípicos ($Q1 - 1.5 \cdot IQR$, $Q3 + 1.5 \cdot IQR$).
- ▶ **Outliers (Puntos Fuera de los Bigotes):** Valores atípicos, significativamente diferentes del resto.


21

Distribución Gaussiana (Normal)

Definición: Una variable aleatoria X sigue una distribución normal si su función de densidad de probabilidad es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- ▶ μ : media
- ▶ σ^2 : varianza
- ▶ Forma de campana, simétrica¹².



¹Algunos fenómenos naturales siguen esta distribución. Se utiliza para modelar variables continuas como la altura, el peso, la inteligencia, entre otras.

²La distribución normal es simétrica y tiene una curva en forma de campana, con la mayoría de los datos agrupados cerca de la media.


24

Distribución Uniforme

Definición: Una variable aleatoria X sigue una distribución uniforme en el intervalo $[a, b]$ si su función de densidad de probabilidad es:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{en otro caso} \end{cases}$$

- Todos los valores tienen la misma probabilidad.
- Distribución rectangular.




25

Distribución Binomial

Definición: Una variable aleatoria X sigue una distribución binomial si cuenta el número de éxitos en n ensayos de Bernoulli³, con probabilidad de éxito p :

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k},$$

- Modela procesos de éxito/fracaso.
- Se aproxima a la normal para n grande.



³Experimentos aleatorios que tienen solo dos posibles resultados: éxito o fracaso. Ejemplo: lanzar una moneda.

26

Histograma de imagen blanco y negro

Imaginemos un histograma de una imagen en blanco y negro donde :

$$h(t) = n_k$$

donde k es $= \{0, \dots, L\}$ donde L es el nivel de grises y n_k el número de píxeles con valores de grises, también podemos normalizarlo por el valor de grises como

$$p(k) = \frac{n_k}{n}$$

n = numero total de pixeles en la imagen


Distribución gaussiana (normal)

Una variable X que sigue la distribución normal:


$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



Feature selection for lineal regression

$$y = \beta_0 + \beta_1x_1 + \beta_2x_2 + \cdots + \beta_px_p +$$



hay veces en las que necesitamos filtrar datos en bases a características





En ridge buscamos reducir los betas, mientras que en lasso eliminamos características

z-score

El **Z-score** (o **t-score**) en regresión mide cuántas desviaciones estándar está un coeficiente $\hat{\beta}_i$ del valor cero. Es una herramienta clave para:

- Evaluar si una variable tiene un efecto significativo sobre y .
- Realizar pruebas de hipótesis sobre $H_0 : \beta_i = 0$.

Un valor alto (en valor absoluto) sugiere que la variable es relevante. Si es bajo, podría ser ruido.

Evalúa el z-score que tanto efecto tiene sobre y , si el valor es alto significa que es relevante si es bajo no es importante

1. Ajustar el modelo:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p +$$

2. Obtener las predicciones:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_p x_p$$

3. Calcular la varianza residual:

$$\hat{\sigma}^2 = \frac{1}{N - p - 1} \sum (y - \hat{y})^2$$

Cuando ajustamos el modelo, obtenemos el valor de predicción, y cuando calculamos esta predicción podemos calcular la varianza residual que nos dice cuanta varianza hay entre nuestro modelo con la predicción

4. Obtener la matriz de varianzas¹ :

$$\text{Var}(\hat{\beta}) = \hat{\sigma}^2 (X^T X)^{-1}$$

5. Calcular el error estándar:

$$SE(\hat{\beta}_i) = \sqrt{\text{Var}(\hat{\beta}_i)}$$

6. Calcular el t-score (Z-score):

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

cada beta nos dara un valor t

1. age: Edad en años.

2. sex: Sexo (masculino o femenino).

3. bmi: Índice de masa corporal (BMI).

4. bp: Presión arterial media.

5. s1: Colesterol sérico total (TC).

6. s2: Lipoproteínas de baja densidad (LDL).
7. s3: Lipoproteínas de alta densidad (HDL).

8. s4: Relación colesterol total/HDL.

9. s5: Logaritmo del nivel de triglicéridos en suero (LTG).

10. s6: Nivel de glucosa en sangre (GLU).

	coef	std err	t
const	152.1335	2.576	59.061
x1	-10.0099	59.749	-0.168
x2	-239.8156	61.222	-3.917
x3	519.8459	66.533	7.813
x4	324.3846	65.422	4.958
x5	-792.1756	416.680	-1.901
x6	476.7390	339.030	1.406
x7	101.0433	212.531	0.475
x8	177.0632	161.476	1.097
x9	751.2737	171.900	4.370
x10	67.6267	65.984	1.025

los valores cercanos a 0 se deberían ignorar, los positivos y negativos grandes son importantes

- El Z-score (o más correctamente, t-score) indica cuántas desviaciones estándar está el coeficiente de $\hat{\beta}_i$ respecto a cero.
- Nos ayuda a decidir si una variable es significativa en el modelo.

Interpretación

► t-score alto ($|t| > 2$): variable probablemente significativa.

► t-score bajo ($|t| \leq 0$): variable no significativa → candidata a eliminar.

Incluir muchas variables irrelevantes puede hacer que el modelo:

- ▶ Sea más complejo de interpretar.
- ▶ Tenga menor capacidad de generalizar (sobreajuste).
- ▶ Tarde más en entrenarse y validarse.

Objetivo

Seleccionar el subconjunto más informativo de variables, descartando las redundantes o inútiles.

Dado un conjunto de datos con muchas variables de entrada, no es recomendable incluir todas las variables de entrada en la ecuación de regresión lineal. En su lugar, es recomendable seleccionar un subconjunto de esas características que pueda predecir la salida con precisión.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p +$$

- ▶ *Stepwise regression* es una técnica de selección de características en la regresión lineal múltiple (MLR).
- ▶ Existen tres tipos de *stepwise regression*: **backward elimination, forward selection, and bidirectional elimination.**

Su propósito principal es identificar y utilizar el subconjunto más relevante de características del dataset, descartando aquellas que son irrelevantes o redundantes - Evitar sobreajuste.

1. Técnicas secuenciales simples:

- ▶ **Forward Selection:** empieza con ninguna variable y las agrega una a una.
- ▶ **Backward Selection:** empieza con todas las variables y elimina las menos útiles.

2. Técnicas avanzadas:

- ▶ **Stepwise Selection:** agrega y elimina variables según su efecto en el modelo.
- ▶ **Recursive Feature Elimination (RFE):** elimina de forma iterativa la variable menos relevante según el modelo.

Backward selection

Backward Selection es una técnica de selección de variables en regresión lineal. Comienza con todas las variables del conjunto de datos e itera eliminando una a una las que aportan menos al modelo, típicamente según su p-valor.

Pasos del algoritmo:

1. Ajustar un modelo con **todas las variables disponibles**.
2. Evaluar la **significancia estadística** de cada variable (usualmente con p-valor o t-score).
3. Eliminar la variable **menos significativa**.
4. Reajustar el modelo y repetir el proceso hasta que todas las variables restantes sean significativas.

Ventajas / Limitaciones:

- ▶ Reduce el riesgo de **sobreajuste** al eliminar variables irrelevantes.
- ▶ Es simple de implementar y comprender.
- ▶ Puede eliminar variables importantes si hay multicolinealidad.
- ▶ No garantiza encontrar el **mejor subconjunto global** de variables.

p-value

1. Calcular el t-value:

$$t = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

2. Consultar la distribución t de Student con $n - p - 1$ grados de libertad:

$$p\text{-value} = 2 \cdot P(T > |t|), \quad T \sim t(df)$$

donde n y p son el número de observaciones y el número de variables independientes, respectivamente.


3. Interpretación:

- ▶ p-valor pequeño (< 0.05): evidencia contra la hipótesis nula $H_0 : \beta_i = 0$.
- ▶ p-valor grande: no hay evidencia suficiente para rechazar H_0 .

Ejemplo:

$$\hat{\beta} = 0,5, \quad SE = 0,2, \quad t = \frac{0,5}{0,2} = 2,5$$
$$df = 50, \quad p = 2 \cdot P(T > 2,5) \approx 0,016$$

Distribución t-Student



- ▶ Distribución de probabilidad que surge del problema de estimar la media de una población normalmente distribuida cuando el tamaño de la muestra es pequeño y la desviación estándar poblacional es desconocida ($k = df$).

Ejemplo: calcular p-value en python

```
1 from scipy import stats
2
3 # t-score observado y grados de libertad
4 t = 2.5
5 df = 50 # n mero de datos - n mero de par metros (betas), mientras m s variables,
6 menos grados de libertad
7
8 # p-valor bilateral
9 p_value = 2 * (1 - stats.t.cdf(abs(t), df))
10 print(f"p-value: {p_value:.4f}") # Resultado: 0.0160
```

en la distribución t-student es como una gaussiana pero desconocemos la desviación estándar

Consultar la distribución t

Se busca conocer cuán probable sería obtener un estadístico t tan extremo como el observado si la hipótesis nula fuera cierta (es decir, si $\beta_i = 0$).

Para eso, comparamos nuestro valor de t con la distribución t de Student, que depende de los grados de libertad del modelo:

$$df = n - p - 1$$

El área bajo la curva desde $|t|$ hacia los extremos nos da el **p-value**. Si ese área es pequeña, el valor observado es poco probable bajo H_0 , y lo rechazamos.

t-value (o Z-score)

Es el estadístico de prueba que mide cuántas desviaciones estándar se aleja el coeficiente $\hat{\beta}_i$ del valor nulo (cero). Se calcula así:

$$t = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

Valores grandes (en valor absoluto) indican mayor evidencia contra la hipótesis nula.

p-value

Es la **probabilidad** de obtener un t-value tan extremo como el observado (o más), **asumiendo que la hipótesis nula es cierta**. Se interpreta así:

- **p pequeño** (por ejemplo, < 0.05): hay evidencia suficiente para rechazar H_0 .
- **p grande**: el coeficiente puede no ser significativamente distinto de cero.

Relación: El t-value se calcula a partir del modelo, y el p-value se obtiene consultando una distribución t de Student con $N - p - 1$ grados de libertad.

Forward step-wise selection

Agrega variables de forma secuencial al modelo, comenzando con ninguna.

► **Paso 0: Modelo Vacío**

- Iniciar con un modelo sin predictores (solo el intercepto).
- Evaluar el rendimiento inicial (ej., $R^2 \approx 0$).

► **Paso 1: Añadir la Primera Característica**

- Evaluar modelos simples con cada característica individualmente.
- Seleccionar la característica que maximiza la mejora del rendimiento.
- Añadir permanentemente esta característica al modelo.

► **Paso 2: Añadir la Siguiente Característica**

- Mantener las características seleccionadas previamente.
- Evaluar modelos añadiendo cada una de las características restantes.
- Seleccionar la característica restante que maximiza la mejora del rendimiento.
- Añadir permanentemente esta característica al modelo.

Pasos Siguientes (iterar)

- Repetir el Paso 2.
- En cada paso, evaluar la adición de cada característica no seleccionada al conjunto actual.
- Añadir la característica que produce la mayor mejora en el rendimiento.

Criterios de Parada

- No hay mejora significativa en el rendimiento.
- Se alcanza un número predefinido de características.
- Criterios basados en pruebas estadísticas (ej., valor p del coeficiente).

Ventajas:

- Computacionalmente más eficiente que probar todas las combinaciones.
- Permite identificar subconjuntos relevantes de variables.

OLS Regression Results

```

=====
Dep. Variable:          y      R-squared:          0.609
Model:                  OLS    Adj. R-squared:       0.609
Method:                 Least Squares    F-statistic:       2815.
Date:                   Wed, 16 Apr 2025    Prob (F-statistic): 0.00
Time:                   07:56:16    Log-Likelihood:    -15823.
No. Observations:      14448    AIC:               3.166e+04
Df Residuals:          14439    BIC:               3.173e+04
Df Model:               8
Covariance Type:       nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	2.0689	0.006	343.624	0.000	2.057	2.081
MedInc	0.8470	0.009	89.283	0.000	0.828	0.866
HouseAge	0.1218	0.007	18.240	0.000	0.109	0.135
AveRooms	-0.3021	0.017	-17.362	0.000	-0.336	-0.268
AveBedrms	0.3690	0.017	21.978	0.000	0.336	0.402
Population	-0.0009	0.006	-0.138	0.890	-0.013	0.012
AveOccup	-0.0350	0.005	-6.889	0.000	-0.045	-0.025
Latitude	-0.8940	0.018	-49.265	0.000	-0.930	-0.858
Longitude	-0.8689	0.018	-48.757	0.000	-0.904	-0.834

```

=====
Omnibus:                2973.049    Durbin-Watson:        1.964
...
Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
=====

```

¿Qué representa el t-value?

Es el estadístico de prueba que indica cuántas desviaciones estándar está el coeficiente estimado $\hat{\beta}_i$ del valor nulo (0):

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

- Valores grandes (en valor absoluto) → mayor evidencia de que $\hat{\beta}_i \neq 0$.

¿Qué representa P>|t|?

Es el **p-valor** asociado al t-score. Indica la probabilidad de observar ese valor (o uno más extremo) si la hipótesis nula es cierta:

$$H_0 : \beta_i = 0$$

- Si $p < 0,05$: evidencia estadística suficiente para rechazar H_0 la variable es significativa.
- Si $p > 0,05$: no hay evidencia suficiente variable posiblemente irrelevante.

Los modelos de regresión lineal requieren variables numéricas. Las variables categóricas (como colores, géneros, regiones) deben ser transformadas para que el modelo las entienda. Las dummy variables permiten incorporar estas categorías de forma cuantitativa sin imponer un orden falso².

- ▶ Variables categóricas convertidas en valores 0 o 1. **Codificación one-hot.**
- ▶ Permiten que los modelos de regresión lineal trabajen con variables cualitativas.

Ejemplo:

Color	Dummy_ Rojo	Dummy_ Verde	Dummy_ Azul
Rojo	1	0	0
Verde	0	1	0
Azul	0	0	1

Modelo de Regresión:

$$y = \beta_0 + \beta_1(\text{Dummy_Rojo}) + \beta_2(\text{Dummy_Verde}) +$$

- ▶ Una Permite que las variables categóricas influyan en el modelo de manera cuantitativa.
- ▶ Los coeficientes representan la diferencia respecto a la categoría de referencia.

²Si la transformarás directamente a números (por ejemplo, rojo = 1, azul = 2, verde = 3), el modelo asumiría que hay un orden entre esos valores (como si verde fuera "mayor"que azul, y azul mayor que rojo).

Q-Q plot

-
- ▶ QQ plot significa “*gráfico cuantil-cuantil*”.
 - ▶ Se utiliza para comparar la distribución de los residuos con una distribución normal teórica.
 - ▶ Es útil para verificar si los errores del modelo de regresión cumplen con el supuesto de normalidad.
 - ▶ En regresión lineal, se asume que los residuos tienen distribución normal.
 - ▶ Si los residuos no son normales, los intervalos de confianza y las pruebas pueden no ser válidos.
 - ▶ El QQ plot ayuda a diagnosticar visualmente esta suposición.
-

Modelo lineal clásico:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \text{con } \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

¿Qué implica esto?

- ▶ Los residuos del modelo (errores) deberían seguir una distribución normal.
- ▶ Este supuesto no afecta la estimación de $\hat{\beta}$, pero sí:
 - La validez de los intervalos de confianza.
 - La interpretación de los p-valores.
 - Las predicciones con incertidumbre.


¿Qué pasa si no se cumple?

- ▶ Los estimadores siguen siendo insesgados, pero la inferencia puede ser errónea.
- ▶ Podemos usar transformaciones (log, raíz) o modelos no paramétricos.

¿Para qué sirve?

Compara la distribución de los residuos con una distribución normal teórica. Es una herramienta visual para diagnosticar si los residuos siguen una distribución normal.

- ▶ **Puntos alineados en la diagonal:** distribución aproximadamente normal.
- ▶ **Curvas en S o desviaciones grandes:** indicios de asimetría o colas pesadas.



La normalidad de residuos es esencial para:


- ▶ Calcular intervalos de confianza para $\hat{y}$ (valor esperado).
- ▶ Estimar intervalos de predicción para nuevas observaciones.
- ▶ Obtener p-valores confiables.


Diagnóstico

Q-Q Plot = Inspección visual del supuesto de normalidad. Si el patrón se desvía mucho de la diagonal, se recomienda:

- ▶ Transformar la variable dependiente (log, raíz).
- ▶ Usar modelos robustos o métodos no paramétricos.

-
- **Intervalos de confianza:** Los intervalos de confianza son rangos que nos dan una idea de cuán seguros estamos sobre los valores estimados por el modelo de regresión. Se usan principalmente en dos contextos:
- Intervalo de confianza para el valor esperado $\hat{y}$ ó Intervalo de confianza para la predicción de una nueva observación.
 - Ayudan a cuantificar la incertidumbre del modelo.
 - Son fundamentales para hacer inferencias confiables.
- Residuos con distribución normal (supuesto).
-





- ▶ Si los puntos siguen una línea recta diagonal, los residuos son aproximadamente normales.
- ▶ Desviaciones sistemáticas alertan posibles problemas:
 - Curvatura en los extremos.
 - Forma de S en el centro se asocia a distribución sesgada.