

Ciencia de datos

Procesamiento y visualización de datos

- variable: característica que se mide u observa en un conjunto de datos
- Observación: conjunto de valores que se registran para una variable en particular
- Distribución: característica o atributo que se mide
- Correlación: relación entre datos

Tipo de datos

Datos estructurados

ID Paciente	Nombre	Apellido	Fecha de Nacimiento	Sexo	Dirección	Teléfono
1	Juan	Pérez	01/01/1990	H	Av. Libertad 123	555-1234
2	María	García	02/02/1992	M	Calle 45 #23	555-5678
3	Pedro	Rodríguez	03/03/1995	H	Av. Independencia 456	555-9012
4	Ana	Sánchez	04/04/1991	M	Calle 12 #56	555-1111

Datos no estructurados

Nombre: Juan Pérez
Edad: 35
Sexo: Masculino
Diagnóstico: Diabetes tipo 2
Medicamentos: - Metformina - Insulina
Alergias: - Penicilina

Archivos JSON y XML.

Datos semi-estructurados

Fuente de datos

registro, sensores, bases de datos, investigaciones, métodos de consulta, etc. Todos esos son métodos para obtener datos.



Procesamiento de datos

Problema de datos:

- Valores faltantes o duplicados
- Valores inconsistentes
- Ruido
- Errores de formato

Técnica y herramientas:

- Eliminación y/o remplazo de datos faltantes

- Corrección de formato
- Eliminación de duplicados

Normalización

Escalado máximo-mínimo (Min-Max)

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Z-score (Estandarización)

$$x' = \frac{x - \mu}{\sigma}$$

Normalización máxima (Max Norm)

$$x' = \frac{x}{x_{\max}}$$

Transformación de variables

Codificación One-Hot

Ejemplo: Rojo $\rightarrow (1,0,0)$, Azul $\rightarrow (0,1,0)$

Codificación ordinal

Ejemplo: Bajo (1), Medio (2), Alto (3)

Discretización de variables numéricas

Ejemplo: $[0, 10] \rightarrow$ "bajo", $[11, 20] \rightarrow$ "medio"

Medida de tendencia central y dispersión

Media
(promedio)

Media aritmética:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

Promedio de los valores de un conjunto de datos.



Desviación
estándar

Fórmula:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

Mide la dispersión de los datos respecto a la media.

Restar la media o estandarizar: Al restar μ_x a los datos se centra el espacio en las medias, por lo que la media de los datos estandarizados es cero ($\mu_x = E[x] = 0$)



- **Varianza:** medida que indica qué tan dispersos están los valores con respecto a la media.


$$\text{var}(x) = \sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)^2$$

- **Covarianza:** representa la tasa de cambio entre dos variables aleatorias.

$$\text{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_x)(y_i - \mu_y)$$

- **Correlación:** mide la relación lineal entre dos variables, estandarizando la covarianza.

$$\text{Corr}(x, y) = \frac{\text{Cov}(x, y)}{\sigma_x \sigma_y}$$



Sea el vector $\mathbf{x} = \{x_1, \dots, x_N\}$, un vector de variables aleatorias.

$$\mathbf{C}_x = \mathbf{C}_x^{N \times N} = (c_{ij} | c_{ij} = \text{Cov}(x_i, x_j))$$

Teniendo en cuenta que $\text{Cov}(x, x) = \sigma_x^2$ y sea $\mathbf{x} = \{x, y, z\}$:


$$\mathbf{C}_x = \begin{pmatrix} \sigma_x^2 & \text{Cov}(x, y) & \text{Cov}(x, z) \\ \text{Cov}(x, y) & \sigma_y^2 & \text{Cov}(y, z) \\ \text{Cov}(x, z) & \text{Cov}(y, z) & \sigma_z^2 \end{pmatrix}$$

- $\mathbf{C}_x$ es una matriz simétrica.
- La matriz de covarianza también se puede definir como:

$$\mathbf{C}_x = E[(\mathbf{x} - \mu_x)(\mathbf{x} - \mu_x)^T] = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k \mathbf{x}_k^T - \mu_x \mu_x^T)$$

► **Escala:**

- La covarianza depende de las unidades de las variables.
- La correlación es adimensional, normalizada entre -1 y 1.




► **Comparabilidad:**

- La covarianza no es directamente comparable entre distintos pares de variables.
- La correlación permite comparaciones directas entre diferentes pares de variables.


Detección de Outliers (Valores Atípicos)

Son datos que se desvían significativamente del patrón general de un conjunto de datos. Pueden ser causados por errores de medición, variabilidad natural o eventos excepcionales.



- **Método de la Distancia:** Identifica outliers basados en la distancia a la media o a otros puntos de datos (e.g., Z-score).
- **Método de la Densidad:** Detecta outliers como puntos con baja densidad de vecinos (e.g., DBSCAN).
- **Otros Métodos:** Incluyen métodos basados en modelos estadísticos, métodos de aprendizaje automático (e.g., Isolation Forest), etc.

Outliers



Boxplot: Resumen Visual de Datos


- ▶ **Mediana (Línea Amarilla):** Valor central, divide los datos en 50/50.
- ▶ **Caja (IQR):** Rango intercuartílico (Q1 a Q3), 50 % central de los datos.
 - Q1: 25 % de los datos por debajo.
 - Q3: 75 % de los datos por debajo.
- ▶ **Líneas "Mínimo" "Máximo":** Límites de datos no atípicos ($Q1 - 1.5 * IQR$, $Q3 + 1.5 * IQR$).
- ▶ **Outliers (Puntos Fuera de los Bigotes):** Valores atípicos, significativamente diferentes del resto.

Distribución Gaussiana (Normal)

Definición: Una variable aleatoria X sigue una distribución normal si su función de densidad de probabilidad es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- ▶ μ : media
- ▶ σ^2 : varianza
- ▶ Forma de campana, simétrica¹².



¹Algunos fenómenos naturales siguen esta distribución. Se utiliza para modelar variables continuas como la altura, el peso, la inteligencia, entre otras.


²La distribución normal es simétrica y tiene una curva en forma de campana, con la mayoría de los datos agrupados cerca de la media.

Distribución Uniforme

Definición: Una variable aleatoria X sigue una distribución uniforme en el intervalo $[a, b]$ si su función de densidad de probabilidad es:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{en otro caso} \end{cases}$$

- Todos los valores tienen la misma probabilidad.
- Distribución rectangular.




Distribución Binomial

Definición: Una variable aleatoria X sigue una distribución binomial si cuenta el número de éxitos en n ensayos de Bernoulli³, con probabilidad de éxito p :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k},$$

- Modela procesos de éxito/fracaso.
- Se aproxima a la normal para n grande.



³Experimentos aleatorios que tienen solo dos posibles resultados: éxito o fracaso. Ejemplo: lanzar una moneda.

Histograma de imagen blanco y negro

Imaginemos un histograma de una imagen en blanco y negro donde :

donde k es $= \{0, \dots, L\}$ donde L es el nivel de grises y el número de píxeles con valores de grises, también podemos normalizarlo por el valor de grises como

n = número total de píxeles en la imagen

Distribución gaussiana (normal)

Una variable X que sigue la distribución normal: