



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Feature Selection for Linear Regression

EIN087B - Ciencia de Datos
Paralelo 701

Profesor: Jorge Portilla G.
`jorge.portilla@usm.cl`

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile

Feature Selection

Feature Selection

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p +$$

All Features




Feature Selection





Final Features





Ridge





Z-score en Regresión Lineal

¿Qué es el Z-score en Regresión?

El **Z-score** (o **t-score**) en regresión mide cuántas desviaciones estándar está un coeficiente $\hat{\beta}_i$ del valor cero. Es una herramienta clave para:

- ▶ Evaluar si una variable tiene un efecto significativo sobre y .
- ▶ Realizar pruebas de hipótesis sobre $H_0 : \beta_i = 0$.

Un valor alto (en valor absoluto) sugiere que la variable es relevante. Si es bajo, podría ser ruido.

1. Ajustar el modelo:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p +$$

2. Obtener las predicciones:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p$$

3. Calcular la varianza residual:

$$\hat{\sigma}^2 = \frac{1}{N - p - 1} \sum (y - \hat{y})^2$$

4. Obtener la matriz de varianzas¹ :

$$\text{Var}(\hat{\beta}) = \hat{\sigma}^2 (X^T X)^{-1}$$

5. Calcular el error estándar:

$$SE(\hat{\beta}_i) = \sqrt{\text{Var}(\hat{\beta}_i)}$$

6. Calcular el t-score (Z-score):

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

¹Esta la covarianza por lo que se extrae la diagonal (varianza)

4. Obtener la matriz de varianzas¹ :

$$\text{Var}(\hat{\beta}) = \hat{\sigma}^2 (X^T X)^{-1}$$

5. Calcular el error estándar:

$$SE(\hat{\beta}_i) = \sqrt{\text{Var}(\hat{\beta}_i)}$$

6. Calcular el t-score (Z-score):

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

Interpretación:

Valores cercanos a 0 coeficiente no significativo.

Valores grandes posible significancia estadística.

¹Esta la covarianza por lo que se extrae la diagonal (varianza)

Z-score en Regresión Lineal

Implementación en Python - Z-score

```
1 import numpy as np
2 from sklearn.linear_model import LinearRegression
3 from sklearn import datasets, linear_model
4 import pandas as pd
5 from scipy import stats
6
7 lm = LinearRegression()
8 lm.fit(X,y)
9 params = np.append(lm.intercept_,lm.coef_)
10 predictions = lm.predict(X)
11
12
13 newX = np.append(np.ones((len(X),1)), X, axis=1)
14 MSE = (sum((y-predictions)**2))/(len(newX)-len(newX[0]))
15
16 var_b = MSE*(np.linalg.inv(np.dot(newX.T,newX)).diagonal())
17 sd_b = np.sqrt(var_b)
18 ts_b = params/ sd_b
19 sd_b = np.round(sd_b,3)
20 ts_b = np.round(ts_b,3)
21 print('Z_score (t-value)', ts_b)
```

1. age: Edad en años.
2. sex: Sexo (masculino o femenino).
3. bmi: Índice de masa corporal (BMI).
4. bp: Presión arterial media.
5. s1: Colesterol sérico total (TC).
6. s2: Lipoproteínas de baja densidad (LDL).
7. s3: Lipoproteínas de alta densidad (HDL).
8. s4: Relación colesterol total/HDL.
9. s5: Logaritmo del nivel de triglicéridos en suero (LTG).
10. s6: Nivel de glucosa en sangre (GLU).

	coef	std err	t
const	152.1335	2.576	59.061
x1	-10.0099	59.749	-0.168
x2	-239.8156	61.222	-3.917
x3	519.8459	66.533	7.813
x4	324.3846	65.422	4.958
x5	-792.1756	416.680	-1.901
x6	476.7390	339.030	1.406
x7	101.0433	212.531	0.475
x8	177.0632	161.476	1.097
x9	751.2737	171.900	4.370
x10	67.6267	65.984	1.025

¿Qué significa el Z-score en regresión?

- ▶ El Z-score (o más correctamente, t-score) indica cuántas desviaciones estándar está el coeficiente de $\hat{\beta}_i$ respecto a cero.
- ▶ Nos ayuda a decidir si una variable es significativa en el modelo.

Interpretación

- ▶ **t-score alto** ($|t| > 2$): variable probablemente significativa.
- ▶ **t-score bajo** ($|t| \approx 0$): variable no significativa $\rightarrow$ candidata a eliminar.

¿Por qué hacer Feature Selection?

Incluir muchas variables irrelevantes puede hacer que el modelo:

¿Por qué hacer Feature Selection?

Incluir muchas variables irrelevantes puede hacer que el modelo:

- ▶ Sea más complejo de interpretar.
- ▶ Tenga menor capacidad de generalizar (sobreajuste).
- ▶ Tarde más en entrenarse y validarse.

Objetivo

Seleccionar el subconjunto más informativo de variables, descartando las redundantes o inútiles.

Dado un conjunto de datos con muchas variables de entrada, no es recomendable incluir todas las variables de entrada en la ecuación de regresión lineal. En su lugar, es recomendable seleccionar un subconjunto de esas características que pueda predecir la salida con precisión.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p +$$

Dado un conjunto de datos con muchas variables de entrada, no es recomendable incluir todas las variables de entrada en la ecuación de regresión lineal. En su lugar, es recomendable seleccionar un subconjunto de esas características que pueda predecir la salida con precisión.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p +$$

- *Stepwise regression* es una técnica de selección de características en la regresión lineal múltiple (MLR).
- Existen tres tipos de *stepwise regression*: **backward elimination, forward selection, and bidirectional elimination.**

Su propósito principal es identificar y utilizar el subconjunto más relevante de características del dataset, descartando aquellas que son irrelevantes o redundantes - Evitar sobreajuste.

Su propósito principal es identificar y utilizar el subconjunto más relevante de características del dataset, descartando aquellas que son irrelevantes o redundantes - Evitar sobreajuste.

1. Técnicas secuenciales simples:

- ▶ **Forward Selection:** empieza con ninguna variable y las agrega una a una.
- ▶ **Backward Selection:** empieza con todas las variables y elimina las menos útiles.

Su propósito principal es identificar y utilizar el subconjunto más relevante de características del dataset, descartando aquellas que son irrelevantes o redundantes - Evitar sobreajuste.

1. Técnicas secuenciales simples:

- ▶ **Forward Selection:** empieza con ninguna variable y las agrega una a una.
- ▶ **Backward Selection:** empieza con todas las variables y elimina las menos útiles.

2. Técnicas avanzadas:

- ▶ **Stepwise Selection:** agrega y elimina variables según su efecto en el modelo.
- ▶ **Recursive Feature Elimination (RFE):** elimina de forma iterativa la variable menos relevante según el modelo.

Backward Selection

Backward Selection es una técnica de selección de variables en regresión lineal. Comienza con todas las variables del conjunto de datos e itera eliminando una a una las que aportan menos al modelo, típicamente según su p-valor.

Pasos del algoritmo:

1. Ajustar un modelo con **todas las variables disponibles**.
2. Evaluar la **significancia estadística** de cada variable (usualmente con p-valor o t-score).
3. Eliminar la variable **menos significativa**.
4. Reajustar el modelo y repetir el proceso hasta que todas las variables restantes sean significativas.

Backward Selection

Backward Selection es una técnica de selección de variables en regresión lineal. Comienza con todas las variables del conjunto de datos e itera eliminando una a una las que aportan menos al modelo, típicamente según su p-valor.

Pasos del algoritmo:

1. Ajustar un modelo con **todas las variables disponibles**.
2. Evaluar la **significancia estadística** de cada variable (usualmente con p-valor o t-score).
3. Eliminar la variable **menos significativa**.
4. Reajustar el modelo y repetir el proceso hasta que todas las variables restantes sean significativas.

Ventajas / Limitaciones:

- ▶ Reduce el riesgo de **sobreajuste** al eliminar variables irrelevantes.
- ▶ Es simple de implementar y comprender.
- ▶ **Puede eliminar variables importantes si hay multicolinealidad.**
- ▶ No garantiza encontrar el **mejor subconjunto global** de variables.

1. Calcular el t-value:

$$t = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

2. Consultar la distribución t de Student con $n - p - 1$ grados de libertad:

$$p\text{-value} = 2 \cdot P(T > |t|), \quad T \sim t(df)$$

donde n y p son el número de observaciones y el número de variables independientes, respectivamente.


3. Interpretación:

- ▶ p-valor pequeño (< 0.05): evidencia contra la hipótesis nula $H_0 : \beta_i = 0$.
- ▶ p-valor grande: no hay evidencia suficiente para rechazar H_0 .

Ejemplo:


$$\begin{aligned} \hat{\beta} &= 0,5, & SE &= 0,2, & t &= \frac{0,5}{0,2} = 2,5 \\ df &= 50, & p &= 2 \cdot P(T > 2,5) \approx 0,016 \end{aligned}$$

Distribución t-Student



- Distribución de probabilidad que surge del problema de estimar la media de una población normalmente distribuida cuando el tamaño de la muestra es pequeño y la desviación estándar poblacional es desconocida ($k = df$).

Distribución t-Student



- Distribución de probabilidad que surge del problema de estimar la media de una población normalmente distribuida cuando el tamaño de la muestra es pequeño y la desviación estándar poblacional es desconocida ($k = df$).

Ejemplo: calcular p-value en python

```

1  from scipy import stats
2
3  # t-score observado y grados de libertad
4  t = 2.5
5  df = 50 # n mero de datos - n mero de par metros (betas), mientras m s variables,
6  menos grados de libertad
7
8  # p-valor bilateral
9  p_value = 2 * (1 - stats.t.cdf(abs(t), df))
10 print(f"p-value: {p_value:.4f}") # Resultado: 0.0160

```

Consultar la distribución t

Se busca conocer cuán probable sería obtener un estadístico t tan extremo como el observado si la hipótesis nula fuera cierta (es decir, si $\beta_i = 0$).

Para eso, comparamos nuestro valor de t con la distribución t de Student, que depende de los grados de libertad del modelo:

$$df = n - p - 1$$

El área bajo la curva desde $|t|$ hacia los extremos nos da el **p-value**. Si ese área es pequeña, el valor observado es poco probable bajo H_0 , y lo rechazamos.


Visualizando el t-value y el p-value

Interpretación gráfica:

- ▶ El **t-value** es una posición en la distribución t de Student.
- ▶ El **p-value** es el área bajo la curva en ambas colas desde ese valor y su opuesto.
- ▶ Un **p pequeño** indica que el valor observado sería muy raro si $\beta = 0$.

Relación clave:

$$p = 2 \cdot \mathbb{P}(T > |t|)$$



Áreas sombreadas = p-value para $t = \pm 2,5$

¿Cuál es la diferencia entre el t-value y el p-value?

t-value (o Z-score)

Es el estadístico de prueba que mide cuántas desviaciones estándar se aleja el coeficiente $\hat{\beta}_i$ del valor nulo (cero). Se calcula así:

$$t = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

Valores grandes (en valor absoluto) indican mayor evidencia contra la hipótesis nula.

p-value

Es la **probabilidad** de obtener un t-value tan extremo como el observado (o más), **asumiendo que la hipótesis nula es cierta**. Se interpreta así:

- ▶ **p pequeño** (por ejemplo, < 0.05): hay evidencia suficiente para rechazar H_0 .
- ▶ **p grande**: el coeficiente puede no ser significativamente distinto de cero.

Relación: El t-value se calcula a partir del modelo, y el p-value se obtiene consultando una distribución t de Student con $N - p - 1$ grados de libertad.

Algoritmo Sequential Backward Selection

```
1  from sklearn.datasets import fetch_california_housing
2  from sklearn.linear_model import LinearRegression
3  from sklearn.model_selection import train_test_split
4  from sklearn.feature_selection import SequentialFeatureSelector
5  from sklearn.preprocessing import StandardScaler
6  import pandas as pd
7
8  data = fetch_california_housing()
9  X, y = data.data, data.target
10 feature_names = data.feature_names
11
12 scaler = StandardScaler()
13 X_scaled = scaler.fit_transform(X)
14
15 X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size=0.3, random_state=42)
16
17 lr = LinearRegression()
18
19 sbs = SequentialFeatureSelector(lr, n_features_to_select=5, direction='backward', scoring='r2', cv=5)
20 sbs.fit(X_train, y_train)
21
22 selected_features = sbs.get_support()
23 selected_feature_names = [name for name, selected in zip(feature_names, selected_features) if selected]
24
25 print("Caracter sticas seleccionadas:", selected_feature_names)
26
27 # Evaluar el modelo con esas caracter sticas
28 X_train_selected = sbs.transform(X_train)
29 X_test_selected = sbs.transform(X_test)
30
31 lr.fit(X_train_selected, y_train)
32 r2_score = lr.score(X_test_selected, y_test)
33
34 print("R del modelo con SBS:", r2_score)
```

Agrega variables de forma secuencial al modelo, comenzando con ninguna.

► **Paso 0: Modelo Vacío**

- Iniciar con un modelo sin predictores (solo el intercepto).
- Evaluar el rendimiento inicial (ej., $R^2 \approx 0$).

► **Paso 1: Añadir la Primera Característica**

- Evaluar modelos simples con cada característica individualmente.
- Seleccionar la característica que maximiza la mejora del rendimiento.
- Añadir permanentemente esta característica al modelo.

► **Paso 2: Añadir la Siguiente Característica**

- Mantener las características seleccionadas previamente.
- Evaluar modelos añadiendo cada una de las características restantes.
- Seleccionar la característica restante que maximiza la mejora del rendimiento.
- Añadir permanentemente esta característica al modelo.

Forward Step-wise Selection (FSS)

Pasos Siguientes (iterar)

- ▶ Repetir el Paso 2.
- ▶ En cada paso, evaluar la adición de cada característica no seleccionada al conjunto actual.
- ▶ Añadir la característica que produce la mayor mejora en el rendimiento.

Criterios de Parada

- ▶ No hay mejora significativa en el rendimiento.
- ▶ Se alcanza un número predefinido de características.
- ▶ Criterios basados en pruebas estadísticas (ej., valor p del coeficiente).

Ventajas:

- ▶ Computacionalmente más eficiente que probar todas las combinaciones.
- ▶ Permite identificar subconjuntos relevantes de variables.

Linear regression using Statsmodels library

```
1 import numpy as np
2 import pandas as pd
3 from sklearn.datasets import fetch_california_housing
4 from sklearn.model_selection import train_test_split
5 from sklearn.preprocessing import StandardScaler
6 import statsmodels.api as sm
7
8 data = fetch_california_housing()
9 X, y = data.data, data.target
10 feature_names = data.feature_names
11
12 scaler = StandardScaler()
13 X_scaled = scaler.fit_transform(X)
14
15 X_df = pd.DataFrame(X_scaled, columns=feature_names)
16
17 X_train, X_test, y_train, y_test = train_test_split(X_df, y, test_size=0.3, random_state=42)
18
19 X_train_const = sm.add_constant(X_train)
20
21 model = sm.OLS(y_train, X_train_const).fit()
22
23 print(model.summary())
24
25 X_test_const = sm.add_constant(X_test)
26 predictions = model.predict(X_test_const)
27
28 r2_score = model.rsquared
29 print("\nR en conjunto de prueba:", round(r2_score, 4))
```

Linear regression using Statsmodels library

OLS Regression Results

```
=====
Dep. Variable:          y      R-squared:                0.609
Model:                  OLS    Adj. R-squared:            0.609
Method:                 Least Squares    F-statistic:        2815.
Date:                   Wed, 16 Apr 2025    Prob (F-statistic):    0.00
Time:                   07:56:16    Log-Likelihood:       -15823.
No. Observations:      14448    AIC:                  3.166e+04
Df Residuals:          14439    BIC:                  3.173e+04
Df Model:               8
Covariance Type:        nonrobust
=====
```

```
=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
const          2.0689      0.006    343.624      0.000        2.057        2.081
MedInc          0.8470      0.009     89.283      0.000        0.828        0.866
HouseAge        0.1218      0.007     18.240      0.000        0.109        0.135
AveRooms       -0.3021      0.017    -17.362      0.000       -0.336       -0.268
AveBedrms       0.3690      0.017     21.978      0.000        0.336        0.402
Population     -0.0009      0.006     -0.138      0.890       -0.013        0.012
AveOccup       -0.0350      0.005     -6.889      0.000       -0.045       -0.025
Latitude       -0.0940      0.018    -49.265      0.000       -0.930       -0.858
Longitude      -0.0689      0.018    -48.757      0.000       -0.904       -0.834
=====
```

```
Omnibus:                2973.049    Durbin-Watson:                1.964
```

...

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Interpretación de los resultados: t y $P > |t|$

¿Qué representa el t -value?

Es el estadístico de prueba que indica cuántas desviaciones estándar está el coeficiente estimado $\hat{\beta}_i$ del valor nulo (0):

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

- Valores grandes (en valor absoluto) $\rightarrow$ mayor evidencia de que $\hat{\beta}_i \neq 0$.

¿Qué representa $P > |t|$?

Es el **p-valor** asociado al t-score. Indica la probabilidad de observar ese valor (o uno más extremo) si la hipótesis nula es cierta:

$$H_0 : \beta_i = 0$$

- Si $p < 0,05$: evidencia estadística suficiente para rechazar H_0 la variable es significativa.
- Si $p > 0,05$: no hay evidencia suficiente variable posiblemente irrelevante.

Los modelos de regresión lineal requieren variables numéricas. Las variables categóricas (como colores, géneros, regiones) deben ser transformadas para que el modelo las entienda. Las dummy variables permiten incorporar estas categorías de forma cuantitativa sin imponer un orden falso².

- ▶ Variables categóricas convertidas en valores 0 o 1. **Codificación one-hot**.
- ▶ Permiten que los modelos de regresión lineal trabajen con variables cualitativas.

Ejemplo:

Color	Dummy_Rojo	Dummy_Verde	Dummy_Azul
Rojo	1	0	0
Verde	0	1	0
Azul	0	0	1

Modelo de Regresión:

$$y = \beta_0 + \beta_1(\text{Dummy_Rojo}) + \beta_2(\text{Dummy_Verde}) +$$

- ▶ Una Permite que las variables categóricas influyan en el modelo de manera cuantitativa.
- ▶ Los coeficientes representan la diferencia respecto a la categoría de referencia.

²Si la transformaras directamente a números (por ejemplo, rojo = 1, azul = 2, verde = 3), el modelo asumiría que hay un orden entre esos valores (como si verde fuera "mayor" que azul, y azul mayor que rojo).

Q-Q Plot

¿Qué es un QQ Plot?

- ▶ QQ plot significa *“gráfico cuantil-cuantil”*.
- ▶ Se utiliza para comparar la distribución de los residuos con una distribución normal teórica.
- ▶ Es útil para verificar si los errores del modelo de regresión cumplen con el supuesto de normalidad.

¿Qué es un QQ Plot?

- ▶ QQ plot significa *“gráfico cuantil-cuantil”*.
- ▶ Se utiliza para comparar la distribución de los residuos con una distribución normal teórica.
- ▶ Es útil para verificar si los errores del modelo de regresión cumplen con el supuesto de normalidad.
- ▶ En regresión lineal, se asume que los residuos tienen distribución normal.
- ▶ Si los residuos no son normales, los intervalos de confianza y las pruebas pueden no ser válidos.
- ▶ El QQ plot ayuda a diagnosticar visualmente esta suposición.

¿Por qué importa la normalidad de los residuos?

Modelo lineal clásico:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \text{con } \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

¿Qué implica esto?

- ▶ Los residuos del modelo (errores) deberían seguir una distribución normal.
- ▶ Este supuesto no afecta la estimación de $\hat{\beta}$, pero sí:
 - La validez de los intervalos de confianza.
 - La interpretación de los p-valores.
 - Las predicciones con incertidumbre.

¿Qué pasa si no se cumple?


- ▶ Los estimadores siguen siendo insesgados, pero la inferencia puede ser errónea.
- ▶ Podemos usar transformaciones (log, raíz) o modelos no paramétricos.

Q-Q significa *Quantile-Quantile plot*

¿Para qué sirve?

Compara la distribución de los residuos con una distribución normal teórica. Es una herramienta visual para diagnosticar si los residuos siguen una distribución normal.

- ▶ **Puntos alineados en la diagonal:** distribución aproximadamente normal.
- ▶ **Curvas en S o desviaciones grandes:** indicios de asimetría o colas pesadas.



La normalidad de residuos es esencial para:


- ▶ Calcular intervalos de confianza para $\hat{y}$ (valor esperado).
- ▶ Estimar intervalos de predicción para nuevas observaciones.
- ▶ Obtener p-valores confiables.


Diagnóstico

Q-Q Plot = Inspección visual del supuesto de normalidad. Si el patrón se desvía mucho de la diagonal, se recomienda:

- ▶ Transformar la variable dependiente (log, raíz).
- ▶ Usar modelos robustos o métodos no paramétricos.

- ▶ **Intervalos de confianza:** Los intervalos de confianza son rangos que nos dan una idea de cuán seguros estamos sobre los valores estimados por el modelo de regresión. Se usan principalmente en dos contextos:
 - Intervalo de confianza para el valor esperado $\hat{y}$ ó Intervalo de confianza para la predicción de una nueva observación.
 - Ayudan a cuantificar la incertidumbre del modelo.
 - Son fundamentales para hacer inferencias confiables.
- ▶ Residuos con distribución normal (supuesto).





- ▶ Si los puntos siguen una línea recta diagonal, los residuos son aproximadamente normales.
- ▶ Desviaciones sistemáticas alertan posibles problemas:
 - Curvatura en los extremos.
 - Forma de S en el centro se asocia a distribución sesgada.



UNIVERSIDAD TÉCNICA
FEDERICO SANTA MARÍA

Feature Selection for Linear Regression

EIN087B - Ciencia de Datos
Paralelo 701

Profesor: Jorge Portilla G.
`jorge.portilla@usm.cl`

Departamento de Electrónica e Informática
Universidad Técnica Federico Santa María
Concepción, Chile